



UNIVERSIDAD DE BUENOS AIRES
FACULTAD DE CIENCIAS EXACTAS Y NATURALES

Segmentación de tumores cerebrales mediante técnicas de deep learning

Tesis de Licenciatura en Ciencias de Datos

Noé Fabián Hsueh

Director: Dr. Enzo Ferrante

Codirector: Dr. Diego Fernández Slezak

Buenos Aires, 2023

SEGMENTACIÓN DE TUMORES CEREBRALES MEDIANTE TÉCNICAS DE DEEP LEARNING

La segmentación de tumores cerebrales, el proceso de delinear áreas de interés en imágenes cerebrales, es vital para la planificación quirúrgica, al proporcionar una localización precisa, esencial para la resección del tumor. Presenta desafíos significativos debido a la variabilidad en la apariencia y ubicación del tumor, el bajo contraste entre el tumor y los tejidos circundantes, y las diferencias en las modalidades de MRI y la calidad de los datos [1]. Los avances recientes en deep learning [2] muestran un potencial significativo para abordar estas complejidades. Esta tesis se centra en desarrollar un modelo para la segmentación de gliomas utilizando un conjunto de datos propietario del hospital FLENI. El rendimiento del modelo se evalúa además en el conjunto de datos LUMIERE [3], un conjunto de datos de MRI longitudinal, para automatizar los criterios RANO (Evaluación de Respuesta en Neuro-Oncología) [4], para la evaluación de la progresión del tumor.

Los desafíos específicos abordados en esta tesis incluyen la integración y el preprocesamiento de datos de MRI multimodal, la adaptación de modelos de segmentación preentrenados a nuevos conjuntos de datos y el establecimiento de un criterio RANO automatizado basado en datos volumétricos. La metodología implica pasos de preprocesamiento, entrenamiento usando nnUNet [5, 6] baseline y region-based. Sin embargo, persisten desafíos en la clasificación precisa de los criterios RANO. Los gráficos de progresión volumétrica desarrollados en esta tesis tienen un potencial para ayudar a los médicos en monitorear la progresión del tumor y la respuesta al tratamiento, al ofrecer información sobre los cambios temporales en el volumen del tumor [7]. A pesar de estos avances, se destaca la necesidad de mejores modelos de segmentación y datos más diversos para mejorar la precisión de la clasificación RANO.

Palabras claves: Segmentación de tumores, Deep Learning, glioma, nnUNet, Criterio RANO.

BRAIN TUMOR SEGMENTATION WITH DEEP LEARNING TECHNIQUE

Brain tumor segmentation, the process of delineating areas of interest in brain images, is vital for surgical planning, providing precise localization essential for tumor resection. It presents significant challenges due to the variability in tumor appearance and location, low contrast between tumor and surrounding tissues, and differences in MRI modalities and data quality [1]. Recent advances in deep learning [2] have shown significant potential in addressing these complexities. This thesis focuses on developing a model for glioma segmentation using a proprietary dataset from the FLENI hospital. The model's performance is further evaluated on the LUMIERE dataset [3], a longitudinal MRI dataset, to automate the RANO (Response Assessment in Neuro-Oncology) criteria [4] for tumor progression evaluation.

The specific challenges addressed in this thesis include the integration and preprocessing of multimodal MRI data, adapting pretrained segmentation models to new datasets, and establishing an automated RANO criterion based on volumetric data. The methodology involves preprocessing steps, baseline and region-based training experiments, and the application of deep learning models, particularly the nnUNet architecture [5, 6]. However, challenges remain in the accurate classification of RANO criteria. The volumetric progression graphs developed in this study hold significant potential for assisting clinicians in monitoring tumor progression and treatment response, offering insights into temporal changes in tumor volume [7]. Despite these advancements, the research highlights the need for better segmentation models and more diverse data to improve RANO classification accuracy.

Keywords: Brain Tumor Segmentation, Deep Learning, Glioma, nnUNet, RANO Criteria.

Índice general

1.. Introducción	1
1.1. Contexto y motivación	1
1.2. Alcances y objetivos	2
1.3. Estructura de la tesis	2
2.. Marco teórico	3
2.1. Tumores cerebrales	3
2.1.1. Tipos de tumores cerebrales y clasificación según OMS	4
2.2. Imágenes médicas cerebrales	6
2.2.1. Física de MRI	6
2.2.2. De física a la imagen	9
2.2.3. Protocolo y clasificación RANO	12
2.3. Modelado	13
2.3.1. Definición del problema	13
2.3.2. Métodos basados en aprendizaje supervisado	16
2.3.3. Trabajos relacionados	22
3.. Desarrollo y metodología	23
3.1. Preprocesamiento	23
3.2. Métricas	26
3.3. Segmentación de tumores	29
3.3.1. Experimento 1: Baseline	29
3.3.2. Experimento 2: Entrenamiento por Regiones	35
3.4. Clasificación RANO	39
3.5. Resumen	43
4.. Conclusiones	44
4.1. Limitaciones y trabajos futuros	44

1. INTRODUCCIÓN

En este capítulo, presentaremos el contexto y la motivación del problema a resolver (1.1), junto al objetivo de la tesis (1.2). La sección 1.3 describe la estructura de la tesis.

1.1. Contexto y motivación

El análisis de imágenes médicas juega un papel crucial en varios aspectos de la investigación médica, el seguimiento y el tratamiento clínico. Dentro de este área, la segmentación de tumores cerebrales, que consiste en delimitar áreas de interés en una imagen cerebral, ayuda en la planificación de cirugías, al proveer una localización precisa, lo cual es vital para la resección quirúrgica ¹. Más aún, la segmentación es una herramienta crucial en el monitoreo postoperatorio, permitiendo evaluar el tumor residual y la potencial recurrencia. En esencia, ayuda a mejorar el porcentaje de supervivencia mediante la diagnosis y la planificación del tratamiento. En esta tesis nos concentraremos en la segmentación de tumores cerebrales con el objetivo de poder luego hacer un seguimiento del tumor mediante el criterio RANO [4], esto es un criterio clínico para evaluar la progresión del tumor tras la resección.

A pesar de su importancia, la segmentación de tumores cerebrales surge como un área particularmente desafiante [1]. Los desafíos principales se resumen en:

- **Variabilidad en la apariencia y ubicación del tumor:** Los tumores cerebrales exhiben una amplia gama de formas, tamaños y ubicaciones, lo que dificulta el desarrollo de un enfoque de segmentación único para todos los casos.
- **Bajo contraste entre el tumor y los tejidos circundantes:** El contraste entre el tumor y los tejidos cerebrales adyacentes en las imágenes de resonancia magnética (MRI) es a menudo bajo, lo que complica la tarea de segmentación.
- **Variaciones en modalidades de MRI y calidad de los datos:** Diferentes modalidades de imágenes de resonancias magnéticas (MRI) (por ejemplo: T1, T2, FLAIR, análogas a canales RGB en imágenes a color, con la particularidad que en este caso resaltan diferentes componentes fisiológicos del tumor) proporcionan información variada, y la calidad de estas imágenes puede variar significativamente, impactando la precisión de la segmentación.
- **Sesgo de anotadores y desequilibrio de datos:** Las anotaciones manuales por parte de los radiólogos pueden ser subjetivas, llevando a sesgos. Además, el desequilibrio en el número de muestras de tejido normal y anormal puede afectar el rendimiento de los algoritmos de segmentación.

Los gliomas representan los tumores cerebrales primarios más prevalentes, caracterizados por su variada agresividad, variada prognosis y sub-regiones histológicas heterogéneas. Esta heterogeneidad no solo complica la resección quirúrgica y hace que algunos tumores sean inoperables, sino que también influye en las evaluaciones longitudinales de la progresión del tumor y las predicciones de las tasas de supervivencia de los pacientes. La

¹ La resección consiste en la cirugía realizada para extraer un tumor o parte de este.

segmentación de gliomas y sus sub-regiones en MRI es uno de los métodos de imagen más usados para planificar cirugías, monitorear resultados postoperatorios y mejorar las probabilidades de supervivencia del paciente.

Avances recientes en deep learning han mostrado un gran potencial para abordar las complejidades de la segmentación de tumores cerebrales [1, 2]. Estas técnicas incluyen desde Redes Neuronales Convolucionales (CNNs) hasta arquitecturas recientes de Transformers, y han revolucionado el análisis de imágenes médicas al automatizar la extracción de características y mejorar la precisión de la segmentación. Varios casos de éxito destacan la eficacia de los métodos de aprendizaje profundo en lograr segmentaciones de tumores cerebrales robustas y precisas, allanando el camino para su adopción generalizada en la práctica clínica.

1.2. Alcances y objetivos

Existe una necesidad urgente de segmentaciones precisas y automatizadas de tumores cerebrales en imágenes de MRI para ayudar en la toma de decisiones clínicas. Los desafíos específicos abordados en esta tesis incluyen:

- **Manejo de datos multimodales de MRI:** Integrar y preprocesar eficazmente la información de diferentes modalidades de MRI para mejorar la precisión de la segmentación.
- **Domain shift (cambio de dominio):** Adaptar modelos de segmentación preentrenados a nuevos conjuntos de datos, que pueden tener características diferentes de los datos de entrenamiento, para asegurar un rendimiento confiable.
- **Criterio RANO:** A partir del modelo desarrollado, establecer un criterio RANO automatizado a partir de datos volumétricos.

En resumen, el objetivo de esta tesis es el desarrollo de un modelo para la segmentación de gliomas utilizando un conjunto de datos exclusivo del hospital FLENI. Posteriormente, se usará el modelo para evaluarse en LUMIERE [3], un dataset de MRI longitudinal para automatizar el criterio RANO.

1.3. Estructura de la tesis

La tesis se organiza en cuatro capítulos. El **Capítulo 1** ofrece una breve introducción, presentando la motivación y los desafíos del problema en estudio. El marco teórico se desarrolla en el **Capítulo 2**. En la sección 2.1, se introduce la terminología médica, enfocándose en los gliomas. La sección 2.2 proporciona una concisa introducción a la física de imágenes por resonancia magnética (MRI). La sección 2.3 define el problema formalmente e introduce el área de segmentación de tumores usando técnicas de deep learning.

El **Capítulo 3** detalla la metodología y el desarrollo de los experimentos realizados, los resultados obtenidos y las decisiones tomadas. Finalmente, el capítulo **Capítulo 4** concluye la tesis proponiendo posibles trabajos futuros.

2. MARCO TEÓRICO

En este capítulo, incluimos un marco teórico para que el lector pueda comprender la metodología usada en el **Capítulo 3**. El capítulo está dividido en tres secciones. En la sección **2.1** explicamos qué son los tumores cerebrales, haciendo énfasis en los gliomas, que son el tipo de tumor que nos interesa segmentar. La sección **2.2** provee una introducción al área de las imágenes médicas, explicamos brevemente el funcionamiento de MRI (**2.2.1**) para entender la procedencia de nuestros datos: imágenes de resonancia magnética multimodales, tanto de glioma de grado alto como de glioma de grado bajo. La subsección **2.2.2** detalla la diferencia entre estas modalidades y la subsección **2.2.3** detalla el protocolo habitual clínico y la clasificación RANO realizada para hacer el seguimiento. Por último, la sección **2.3** define formalmente el problema e introduce el área de segmentación cerebral usando técnicas de deep learning.

2.1. Tumores cerebrales

Un tumor cerebral se define como una masa anormal de tejido en la que las células crecen dentro del sistema nervioso central (SNC) y se multiplican de manera incontrolada por los mecanismos que regulan las células normales. Los tumores pueden originarse en el propio tejido cerebral, en las meninges ¹, en los nervios craneales o a partir de células cancerosas metastásicas que provienen de otras partes del cuerpo.

Los tumores cerebrales se pueden clasificar en dos categorías: tumores primarios y secundarios (metastásicos) [8, 9].

- **Tumores cerebrales primarios:** Estos se originan dentro del cerebro o del sistema nervioso central. Pueden surgir de varios tipos de células dentro del cerebro, incluyendo neuronas, células gliales (astrocitos, oligodendrocitos, células ependimarias) y otros tipos de células como las células meníngeas. Los tumores cerebrales primarios pueden ser benignos (no cancerosos) o malignos (cancerosos). Ejemplos incluyen gliomas (astrocytomas, oligodendrogliomas y glioblastomas), meningiomas y schwannomas.
- **Tumores cerebrales secundarios (metastásicos):** Estos tumores se originan a partir de células cancerosas que se han propagado al cerebro desde otras partes del cuerpo a través del torrente sanguíneo o del sistema linfático. Los tumores cerebrales secundarios son siempre malignos y representan el tipo más común de tumor cerebral en adultos. Los sitios primarios comunes para los cánceres que metastatizan al cerebro incluyen los pulmones, las mamas, la piel (melanoma), los riñones y el colon.

Estadísticas generales y tasas de incidencia Los tumores cerebrales representan un desafío médico significativo debido a su naturaleza compleja y su impacto en el SNC. Según las estadísticas globales de cáncer [10], los tumores cerebrales malignos primarios representan aproximadamente el 2 % de todos los cánceres diagnosticados anualmente. Sin

¹ Las membranas protectoras que cubren el cerebro y la médula espinal.

embargo, su impacto es desproporcionadamente alto debido a su ubicación crítica y su comportamiento a menudo agresivo.

La incidencia de los tumores cerebrales primarios varía según la región, la edad, el sexo y la etnia. En Argentina, el Instituto Nacional del Cáncer informa una tasa de incidencia anual de entre 4.5 % y 19.6 % casos por 100,000 personas para todos los tumores primarios del cerebro y del SNC. De estos, el 70 % se originan en el cerebro, la médula espinal o sus cubiertas meníngeas y el 30 % restante corresponde a metástasis de un tumor localizado en otra región del cuerpo [11, 12].

Estas estadísticas subrayan la importancia de la detección temprana, el diagnóstico preciso y el desarrollo de modalidades de tratamiento eficaces para manejar y tratar los tumores cerebrales de manera efectiva. La complejidad y variabilidad de los tumores cerebrales requieren un enfoque multidisciplinario que combine neurología, oncología, radiología y, cada vez más, métodos computacionales para un diagnóstico y planificación del tratamiento mejorados.

2.1.1. Tipos de tumores cerebrales y clasificación según OMS

El glioma es uno de los tipos más importantes de tumores cerebrales primarios, ya que representan aproximadamente el 30 % de todos los tumores del SNC y aproximadamente el 80 % de todos los tumores cerebrales malignos [13]. El glioma se puede clasificar en varios grados. Aquí proporcionamos una breve clasificación, para una clasificación más detallada, consulte [14].

- Los astrocitomas son un tipo de glioma que se originan en los astrocitos, las células gliales en forma de estrella que proporcionan soporte y nutrientes a las neuronas. Estos tumores pueden ocurrir en cualquier parte del cerebro o la médula espinal y varían ampliamente en su tasa de crecimiento y potencial de malignidad. Los astrocitomas de alto grado, también conocidos como glioblastoma multiforme (GBM), son el tumor cerebral primario maligno más agresivo y común en adultos. Los glioblastomas se caracterizan por un crecimiento rápido, necrosis y una proliferación vascular significativa. El pronóstico para el glioblastoma es desfavorable, con tiempos de supervivencia media típicamente inferiores a 15 meses a pesar del tratamiento agresivo.
- Los gliomas del tronco encefálico, o gliomas difusos infiltrantes del tronco encefálico (DIPG), son tumores raros y agresivos que afectan principalmente a niños en edad escolar y son difíciles de tratar debido a su ubicación crítica en el tronco encefálico.
- Los ependimomas, que se originan a partir de las células ependimarias que recubren los ventrículos del cerebro o la médula espinal, también son raros pero constituyen una parte significativa de los tumores cerebrales pediátricos, a menudo causando hidrocefalia obstructiva. Los gliomas mixtos, o oligoastrocitomas, contienen varios tipos de células gliales y se encuentran típicamente en el cerebro, predominantemente en hombres adultos, siendo su clasificación controvertida y potencialmente resoluble mediante cribado genético.
- Los oligodendrogliomas, que se desarrollan a partir de los oligodendrocitos, las células gliales responsables de producir mielina en el sistema nervioso central, representan del 2 al 4 % de los tumores cerebrales primarios, afectando principalmente a hombres

jóvenes y de mediana edad, con síntomas que incluyen convulsiones y un pronóstico generalmente mejor que otros gliomas debido a su crecimiento más lento y a su respuesta al tratamiento.

Adicionalmente, el sistema de clasificación de la OMS clasifica los tumores cerebrales según sus características histopatológicas y genéticas, incluyendo la apariencia celular, la actividad mitótica y la necrosis. Este sistema proporciona una forma estandarizada de evaluar la malignidad y la agresividad de los tumores cerebrales, guiando las decisiones de tratamiento y el pronóstico [9, 14].

- **Grado I:** Tumores con bajo potencial proliferativo y la posibilidad de cura tras la resección quirúrgica. Ejemplos incluyen el astrocitoma pilocítico, un tumor cerebral que ocurre más comúnmente en niños y adultos jóvenes.
- **Grado II:** Tumores con crecimiento infiltrativo ² y baja actividad mitótica ³. Estos tumores tienen el potencial de progresar a grados superiores con el tiempo. Ejemplos incluyen el astrocitoma difuso y el oligodendroglioma.
- **Grado III:** Tumores con mayor actividad mitótica y evidencia de malignidad. Estos tumores son más agresivos y tienen un pronóstico peor. Ejemplos incluyen el astrocitoma anaplásico ⁴ y el oligodendroglioma anaplásico.
- **Grado IV:** Tumores altamente malignos con crecimiento rápido, necrosis y significativa proliferación vascular. Estos tumores tienen el peor pronóstico. Ejemplos incluyen el glioblastoma.

Los grados I y II se etiquetan como gliomas de bajo grado, mientras que los grados III y IV se etiquetan como gliomas de alto grado.

En la segmentación de imágenes médicas, las subregiones específicas dentro de los tumores cerebrales son de particular interés debido a sus implicaciones patológicas y clínicas distintivas. Estas subregiones normalmente incluyen:


1. Enhancing tumor (tumor realzado): Esta región aparece en las exploraciones por imagen porque absorbe agentes de contraste, lo que indica crecimiento tumoral activo y agresivo.
2. Necrosis: Esta área consiste en células muertas dentro del tumor, resultado de que el tumor ha superado su suministro de sangre.
3. Non-enhancing tumor (tumor no realzado): Esta parte del tumor no absorbe materiales de contraste y puede incluir células tumorales menos activas o en reposo.
4. Edema: Esto se refiere a la hinchazón causada por la acumulación de líquido alrededor del tumor, afectando la función y la salud del cerebro.

² Cáncer que se ha extendido más allá de la capa de tejido en la que se desarrolló y está creciendo en tejidos circundantes y sanos.


³ El índice de actividad mitótica, que mide la actividad proliferativa de las células tumorales, se determina contando las mitosis observadas bajo un microscopio, utilizando una rejilla para mayor precisión. Este índice se calcula en base a la proporción de mitosis respecto al número total de núcleos analizados.

⁴ Un término utilizado para describir las células cancerosas que se dividen rápidamente y tienen poca o ninguna semejanza con las células normales.

Las imágenes en la Figura 2.1 proporcionan ejemplos de gliomas de alto y bajo grado del conjunto de datos FLENI en cuatro modalidades de imagen (T1, T1ce, T2 y FLAIR), análogas a los canales de colores RGB. La región roja indica edema, la región azul muestra la región realzada, la región amarilla representa necrosis y la región verde denota el área del tumor no realzada.



(a) Ejemplo de glioma de alto grado.



(b) Ejemplo de glioma de bajo grado.

Fig. 2.1: Ejemplos de gliomas de alto y bajo grado del conjunto de datos provisto por el hospital FLENI con 4 modalidades de imagen. La región roja indica **edema**, la región azul muestra la **región realzada**, la región amarilla es **necrosis** y la región verde representa el área del **tumor no realzada**.

2.2. Imágenes médicas cerebrales

Las imágenes médicas cerebrales son herramientas fundamentales en el diagnóstico, tratamiento y manejo de los tumores cerebrales. Las herramientas más comunes consisten en la Imágenes por Resonancia Magnética (MRI), mientras que la Tomografía Computarizada (CT) y la Tomografía por Emisión de Positrones (PET) también proporcionan vistas detalladas y no invasivas de la anatomía y patología cerebral. Todas estas modalidades de imagen permiten a los médicos visualizar y evaluar la estructura y función del cerebro, facilitando la detección temprana de anomalías, la localización precisa de tumores y el monitoreo de la respuesta al tratamiento. Por ejemplo, las MRI son indispensables para identificar subregiones específicas dentro de los tumores, como el núcleo tumoral realzado, las áreas necróticas y no realzadas, y el edema. Presentaremos una breve descripción de las MRI, ya que los principales conjuntos de datos con los que trabajamos consisten en este tipo de imágenes. Para una explicación detallada de cómo funcionan las MRI, consulte [15].

2.2.1. Física de MRI

En las máquinas de MRI, se utilizan imanes poderosos para crear un campo magnético fuerte y uniforme. Típicamente, estos imanes son superconductores, lo que significa que se enfrían a temperaturas muy bajas para permitir que las corrientes eléctricas fluyan sin resistencia. Este campo magnético fuerte es esencial porque alinea los momentos magnéticos de los núcleos de hidrógeno en el cuerpo.

Los átomos de hidrógeno tienen una propiedad intrínseca conocida como spin, visualizada como la rotación de una esfera alrededor de un eje en la Figura 2.2. Se pueden pensar como brújulas magnéticas. En ausencia de un campo magnético externo, los spins están distribuidos aleatoriamente, por lo que la suma de todos los campos magnéticos es $\mathbf{0}$. Cuando se colocan bajo un campo magnético (campo vectorial) $\mathbf{B}_0$ ⁵, se alinean ya sea paralelos o antiparalelos al campo, similar a las agujas de una brújula. La mayoría de estos núcleos de hidrógeno se alinean paralelos al campo magnético, creando una magnetización neta en esa dirección. Llamamos a la suma de este vector de magnetización neta $\mathbf{M}$. Bajo el campo magnético $\mathbf{B}_0$, las partículas precesan alrededor del eje del campo magnético con una frecuencia angular ω , llamada frecuencia de Larmor:

$$\omega = \gamma \mathbf{B}_0$$

donde γ es la relación giromagnética, una relación dependiente de la fuerza del campo para un núcleo específico, que es 42.576MHz/T para el hidrógeno (cf. Fig. 2.3).



Fig. 2.2: Visualización del spin de los núcleos de hidrógeno. Imagen tomada de [15]




Fig. 2.3: De izquierda a derecha: los spins de los núcleos dentro del cuerpo se orientan inicialmente al azar, hasta que un campo magnético fuerte hace que sus ejes de rotación se alineen parcialmente con el campo magnético aplicado $\mathbf{B}_0$, lo que lleva a la magnetización acumulada de todos los spins $\mathbf{M}$ precesando alrededor de $\mathbf{B}_0$. Imagen tomada de [15].

De manera análoga a nuestra aguja de la brújula, empujaremos $\mathbf{M}$ fuera de su posición estable (por medio del campo magnético $\mathbf{B}_0$). Este proceso, denominado excitación, emite ondas de radiofrecuencia (RF) medibles. La dirección de $\mathbf{M}$ puede modificarse mediante un campo magnético más débil $\mathbf{B}_1$ en una dirección ortogonal a $\mathbf{B}_0$ al aplicar ondas de RF en la frecuencia de resonancia de $\mathbf{M}$. Esto hace que el vector de magnetización $\mathbf{M}$ se

⁵ este campo magnético es aproximadamente 21,000 veces mayor que el campo natural de la Tierra, generalmente 1.5 T.

incline lejos de su eje original, ya que causa que algunos spins de las partículas se alineen en la dirección antiparalela.




Fig. 2.4: Visualización del proceso de relajación. Después de aplicar magnetización ortogonal $\mathbf{B}_1$, nuestro vector M está en el plano xy , que es el punto de partida para el proceso de relajación. La magnetización sigue la trayectoria azul hasta que se alcanza el estado de reposo (vector verde). El vector M puede descomponerse en dos componentes: vista desde arriba, es decir, plano xy M_{xy} o vista desde el eje longitudinal M_z , por ejemplo, plano xz .

Cuando se apaga el pulso de RF, los núcleos de hidrógeno comienzan a relajarse de nuevo a su alineación original con el campo magnético principal. Durante este proceso, se emiten ondas de RF desde el cuerpo y se pueden recibir con bobinas colocadas cerca de la superficie del cuerpo. Esta es la señal a partir de la cual se generan las imágenes de RM. Del fenómeno de la relajación, generalmente podemos distinguir dos tipos, basados en el hecho de que podemos dividir el vector de magnetización en un componente longitudinal y transversal: $\mathbf{M} = \mathbf{M}_{xy} + \mathbf{M}_z$ (cf. Figura 2.4).

1. Relajación T1 (longitudinal), un proceso llamado relajación spin-lattice, mediante el cual los protones liberan la energía recibida. La recuperación de la magnetización longitudinal sigue la siguiente función exponencial:

$$\|\mathbf{M}_z(t)\| = \|\mathbf{M}_0\|(1 - e^{-\frac{t}{T_1}})$$

seguida por una constante T_1 dependiente del tejido, definida como el período de tiempo para M_z : $1 - \frac{1}{e} \approx 63\%$. $\mathbf{M}_0$ es la magnetización neta en equilibrio que depende de la densidad de protones y de la fuerza del campo magnético externo.

2. Relajación T2 (transversal), un proceso llamado relajación spin-spin. Este fenómeno es causado por interacciones aleatorias entre núcleos, lo que lleva a diferencias de fase temporales. Puede pensarse como un conjunto de relojes girando en la misma fase hasta que todos se desfasan. El movimiento desfasado agregado se puede medir, y sigue:

$$\|\mathbf{M}_{xy}(t)\| = \|\mathbf{M}_0\|e^{-\frac{t}{T_2}}$$

donde T_2 se define como el tiempo después de la excitación cuando el valor de la señal disminuye a $\frac{1}{e} \approx 37\%$.

Las dos constantes son clave para el contraste de la imagen y la definición de las diferentes secuencias de MRI. En los sistemas de MRI, el componente transversal del vector de magnetización neta, $\mathbf{M}_{xy}$, se puede medir y transformar en imágenes: tanto los datos de frecuencia como de fase se recopilan en lo que comúnmente se llama k-space. Una transformada de Fourier bidimensional de este espacio es computada por una computadora para producir una imagen en escala de grises. Los detalles técnicos se pueden encontrar aquí [15].

2.2.2. De física a la imagen

Para adquirir diferentes modalidades de RM, se pueden usar diferentes esquemas de adquisición, basados en diferentes protocolos de escaneo. Spin Echo (SE) es uno de los métodos de medición en MRI utilizado para generar imágenes ponderadas en T1 y T2. La secuencia SE comienza con un pulso de RF de 90 grados que voltea el vector de magnetización neta en el plano transversal. Un pulso de RF subsecuente de 180 grados reenfoca los spins, corrigiendo el desfase causado por inhomogeneidades del campo magnético y generando una señal (cf. Figura 2.5). Los parámetros de tiempo, Tiempo de Repetición (TR) y Tiempo de Eco (TE), son críticos para determinar el contraste de la imagen. TR es el tiempo entre pulsos sucesivos de 90 grados, y TE es el tiempo entre el pulso inicial de 90 grados y el pico de la señal que se mide.




Fig. 2.5: Diagrama de Spin Echo. Líneas punteadas indica que algunos núcleos poseen spin más rápidos y líneas discontinuas, más lentos. Imagen tomada de [15]

Las imágenes ponderadas en T1 se obtienen típicamente con valores cortos de TR

y TE para maximizar el contraste de T1, destacando las diferencias en los tiempos de relajación T1 de varios tejidos. En estas imágenes, los tejidos con tiempos de relajación T1 más cortos aparecen más brillantes, mientras que aquellos con tiempos de T1 más largos aparecen más oscuros. Este mecanismo de contraste es particularmente útil para distinguir entre diferentes tipos de tejidos, como la materia gris, la materia blanca y el líquido cefalorraquídeo (LCR). La capacidad de manipular TR y TE permite la optimización de las imágenes ponderadas en T1 para mejorar el detalle anatómico y la precisión diagnóstica.

Las imágenes ponderadas en T2, por otro lado, se obtienen con valores largos de TR y TE para mejorar el contraste de T2. En las imágenes ponderadas en T2, los tejidos con tiempos de relajación T2 más largos aparecen más brillantes, lo que resulta particularmente útil para identificar cambios patológicos como edema o inflamación, que tienen un mayor contenido de agua y, por lo tanto, tiempos de relajación T2 más largos. Las imágenes ponderadas en densidad de protones (PD), utilizando valores intermedios de TR y TE, reflejan la densidad de protones de hidrógeno en los tejidos. Estos contrastes son esenciales para distinguir entre diferentes tipos de tejidos e identificar cambios patológicos, proporcionando información crucial para un diagnóstico y planificación de tratamiento precisos en la práctica clínica.

Finalmente, los agentes de contraste se utilizan frecuentemente en MRI para mejorar aún más la calidad de la imagen y la capacidad diagnóstica. Los agentes de contraste, como los compuestos a base de gadolinio, se inyectan en el torrente sanguíneo del paciente y se acumulan en tejidos específicos, alterando sus propiedades magnéticas. Esto resulta en un aumento de la intensidad de la señal en las imágenes ponderadas en T1, mejorando así la visibilidad de los vasos sanguíneos, tumores y áreas con barreras hematoencefálicas⁶ alteradas. El uso de agentes de contraste permite una delineación más precisa de las estructuras patológicas y mejora la precisión diagnóstica general de la MRI.

Modalidades: T1, T1CE, T2, FLAIR

En la práctica clínica, típicamente se adquieren varias modalidades de MRI para proporcionar una visión diagnóstica integral del cerebro. Cada modalidad tiene su especificidad y aplicación en la identificación de diversas estructuras cerebrales y anomalías.

T1 (ponderada en T1): Las imágenes ponderadas en T1 proporcionan información estructural detallada sobre los tejidos cerebrales, mostrando los contornos y límites de diferentes estructuras anatómicas con alta resolución. Esta modalidad es particularmente efectiva para visualizar la anatomía del cerebro, incluida la diferenciación entre materia gris y blanca, y se utiliza a menudo para evaluar la anatomía cerebral normal y detectar anomalías como atrofia cerebral o lesiones.

T1 con contraste (ponderada en T1 con contraste): Similar a la imagen ponderada en T1, las imágenes ponderadas en T1 con contraste (T1ce o T1gd) implican la administración de un agente de contraste a base de gadolinio. Este agente de contraste mejora la visibilidad de ciertas estructuras, especialmente aquellas con una barrera hematoencefálica alterada, como los tumores. Las imágenes T1ce son cruciales para mejorar la

⁶ Barrera protectora entre los vasos sanguíneos del cerebro y los tejidos cerebrales que permite que la sangre fluya libremente hacia el cerebro pero evita que la mayoría de las sustancias del torrente sanguíneo lleguen a las células cerebrales.




Fig. 2.6: Ejemplos de modalidades de imagen. Aquí se muestran parches de imagen con las estructuras tumorales que están anotadas en las diferentes modalidades (arriba a la izquierda) y las etiquetas finales para todo el ejemplo completo (a la derecha). Los parches de imagen muestran de izquierda a derecha: el tumor completo visible en FLAIR (A), el núcleo tumoral visible en T2 (B), las estructuras tumorales realzadas visibles en T1c (azul), rodeando los componentes necróticos del núcleo (verde) (C). Las segmentaciones se combinan para generar las etiquetas finales de las estructuras tumorales (D): edema (amarillo), núcleo non enhancing (rojo), núcleo necrótico (verde), núcleo enhancing (azul). Imagen tomada de [16].

delimitación de los márgenes del tumor, identificar lesiones más pequeñas y proporcionar una visualización detallada de los vasos sanguíneos y otras estructuras vasculares dentro del cerebro.

T2 (ponderada en T2): Las imágenes ponderadas en T2 son particularmente útiles para resaltar fluidos dentro del cerebro, lo que las hace ideales para detectar condiciones como el edema cerebral peritumoral, quistes y otras anomalías relacionadas con fluidos. Los tejidos con mayor contenido de agua aparecen más brillantes en las imágenes ponderadas en T2, lo que ayuda a identificar cambios patológicos asociados con el aumento de fluidos, como la inflamación o hinchazón, proporcionando información para diagnosticar varios trastornos cerebrales.

FLAIR (Recuperación de Inversión Atendida por Fluido): La imagen FLAIR suprime la señal del líquido cefalorraquídeo (LCR) utilizando secuencias de pulso de inversión combinadas con un tiempo de inversión específico (TI)⁷. Esta supresión mejora la visibilidad de las lesiones y los tejidos circundantes al anular la señal del LCR, facilitando la detección de anomalías adyacentes a los espacios llenos de líquido. Las imágenes FLAIR son particularmente efectivas para identificar lesiones asociadas con enfermedades desmielinizantes, gliosis⁸ y otras patologías cercanas al LCR, proporcionando información crítica sobre anomalías del tejido cerebral que podrían estar ocultas en otras modalidades de imagen.

Juntas, estas cuatro modalidades de MRI—T1, T1ce, T2 y FLAIR—proporcionan una visión integral de la anatomía y patología cerebral, esencial para un diagnóstico preciso y una planificación de tratamiento efectiva en pacientes con tumores cerebrales y otras

⁷ El TI es el tiempo entre una señal de 180 grados y una de 90 grados.

⁸ una proliferación fibrosa de células gliales en áreas lesionadas del SNC.

condiciones neurológicas. Aunque existen modalidades adicionales de MRI que pueden ofrecer más información, esta tesis se centrará en estas cuatro modalidades claves para analizar y segmentar tumores cerebrales.

2.2.3. Protocolo y clasificación RANO

Los protocolos clínicos estandarizados en la obtención de imágenes por MRI son cruciales para garantizar la consistencia y precisión en la evaluación de tumores cerebrales. El flujo de trabajo clínico para la obtención de imágenes de tumores cerebrales comienza con la preparación del paciente, incluidas instrucciones específicas y el uso de sedación o anestesia si es necesario. Las secuencias rutinarias de MRI, como T1, T1 con contraste (T1c), T2 y FLAIR, se realizan con configuraciones de parámetros específicos (TR, TE y TI para FLAIR) para proporcionar imágenes diagnósticas detalladas. La administración de agentes de contraste a base de gadolinio sigue un procedimiento cuidadosamente cronometrado para mejorar la visualización de ciertas estructuras, particularmente los límites del tumor. La secuencia de adquisición de imágenes se planifica meticulosamente, seguida de técnicas de posprocesamiento para mejorar la calidad de la imagen. Después de la obtención de imágenes, se emplean métodos estandarizados para evaluar e interpretar los resultados de la MRI, y se establecen pautas para escaneos de seguimiento para monitorear la respuesta al tratamiento y la progresión del tumor, asegurando una atención integral al paciente.

RANO: Los criterios de RANO (Evaluación de la Respuesta en Oncología Neurooncológica) [4] proporcionan pautas detalladas para medir e interpretar los cambios en los tumores cerebrales utilizando MRI. Establecidos en 2010, los criterios RANO se han convertido en el estándar para evaluar gliomas, mejorando la capacidad de monitorear la progresión de la enfermedad y la eficacia del tratamiento de manera integral.

Los criterios RANO implican principalmente la evaluación de cambios en el tamaño del tumor utilizando MRI. En criterios bidimensionales, las mediciones se toman de imágenes axiales ponderadas en T1 post-contraste, capturando el diámetro máximo y una segunda medición perpendicular para determinar el área del tumor. La respuesta del tumor se clasifica en cuatro tipos principales: complete response (CR, respuesta completa), partial response (RP, respuesta parcial), stable disease (enfermedad estable) y progressive disease (PD, progresión). La respuesta completa requiere la desaparición de todo el tumor realizado sostenida durante al menos cuatro semanas, sin nuevas lesiones y lesiones FLAIR/T2 no realizadas estables o mejoradas. La respuesta parcial indica una disminución del 50 % o más en el tamaño de las lesiones realizadas medibles, mientras que la enfermedad estable no muestra cambios significativos en el tamaño del tumor. La progresión se define por un aumento del 25 % o más en las lesiones realizadas o la aparición de nuevas lesiones.

Las imágenes ponderadas en T1 con y sin contraste (T1 y T1c) son cruciales para la evaluación RANO, ya que proporcionan una visualización detallada de la estructura vascular del tumor y la integridad de la barrera hematoencefálica. Las imágenes T1c, mejoradas con agentes de contraste a base de gadolinio, ayudan a identificar regiones tumorales activas y diferenciarlas de áreas necróticas. Las imágenes ponderadas en T2 y FLAIR complementan esto resaltando cambios en el contenido de agua, como el edema, que a menudo se asocia con tumores.

Un aspecto esencial de la clasificación RANO es la diferenciación entre la verdadera progresión del tumor y la pseudoprogresión. La pseudoprogresión es un efecto relacionado

con el tratamiento que imita el crecimiento del tumor en las imágenes, pero en realidad se debe a la inflamación u otros cambios transitorios. Este fenómeno es particularmente común en pacientes sometidos a radioterapia y ciertas quimioterapias. Los criterios RANO incorporan síntomas clínicos e imágenes de seguimiento para distinguir entre estas condiciones, evitando cambios prematuros en el tratamiento basados en resultados de imagen engañosos.

Resumen

La sección anterior sienta las bases para comprender las técnicas de imagen y segmentación discutidas en los capítulos siguientes. Primero, explicamos qué son los tumores cerebrales haciendo énfasis en los gliomas, que son el tipo de tumor que pretendemos segmentar. Cubrimos su clasificación en tipos primarios y secundarios, sus subtipos y el sistema de clasificación de la OMS. Los gliomas, y los glioblastomas en particular, son los tumores cerebrales primarios malignos más comunes y a menudo se diagnostican mediante exploraciones de MRI. Luego, introducimos el campo de la imagen médica, particularmente la MRI, para explicar la fuente de nuestros datos: imágenes de resonancia magnética multimodal. Nuestros conjuntos de datos incluyen datos tanto de gliomas de alto grado como de bajo grado. En las exploraciones de MRI, a menudo se pueden discriminar diferentes subestructuras tumorales. En esta tesis, las subestructuras tumorales que consideraremos están compuestas por: enhancing tumor, non enhancing tumor, necrosis y edema. Estas subestructuras se identifican de la siguiente manera: enhancing tumor aparece hiperintenso en T1c e hipointenso en T1, edema aparece hiperintenso en FLAIR y T2, y el necrosis aparece hiperintenso en T2 e hipointenso en T1c y a menudo también en FLAIR. También explicamos los criterios RANO utilizados para la evaluación y seguimiento de tumores cerebrales.

2.3. Modelado

Nuestro objetivo consiste en segmentar un tumor cerebral, esto consiste en clasificar cada voxel (pixel tridimensional) de una imagen multimodal volumétrica con un label (cf. Figura 2.7). En esencia, es un problema de clasificación. Para este propósito, la literatura propone diferentes metodologías para modelar el clasificador f . En esta tesis nos enfocaremos en los métodos de deep learning. La siguiente subsección (2.3.1) define formalmente el problema y la subsección 2.3.2 propone una vision general de los conceptos importantes en deep learning, donde discutiremos el modelo utilizado a lo largo de nuestra tesis: nnUNet. Por último, la subsección 2.3.3 proporciona una breve descripción de otras metodologías utilizadas en la literatura.

2.3.1. Definición del problema

Formalizaremos el problema a investigar de la siguiente manera: consideramos una imagen $\mathcal{I} : \Omega \subset \mathbb{R}^{\{2,3\}} \rightarrow \mathcal{V}$, donde un objeto en el espacio (generalmente de dos o tres dimensiones) es mapeado *continuamente* a un rango de valores; por ejemplo, en el caso de imágenes a color $\mathcal{V} = [0, 255]^3 \subset \mathbb{R}^3$. En nuestro caso, nuestras imágenes son resonancias magnéticas de distintas modalidades $\mathcal{I} : \Omega \subset \mathbb{R}^3 \rightarrow [0, 1]^4$. Las modalidades (T1, T1ce, T2, FLAIR, descritas en la Sección 2.2) son análogas a los canales de color en una imagen RGB y para el análisis posterior puede considerarse como tales.




Fig. 2.7: Overview de segmentación de tumores cerebrales

Notemos que en la práctica, las imágenes son discretizadas. Consideramos que esta cuantización se obtiene a partir de un muestreo de la distribución original, por lo que un vóxel ($\in \mathbb{R}^3$) o un píxel ($\in \mathbb{R}^2$) es solamente una muestra de la imagen.

Definición 2.3.1 (Segmentación de tumores cerebrales). Dado una imagen perteneciente a un dataset $\mathcal{I} \in \mathcal{D}$ con cuatro modalidades, el problema de segmentación tumoral busca delimitar las distintas regiones tumorales en el cerebro. Esto es, clasificar cada vóxel o píxel del input en las regiones tumorales definidas (e.g: fondo, edema, necrosis, tumor realzante).

$$\hat{\mathcal{I}}_{\text{seg}} = f_{\theta}(\mathcal{I}), \quad (2.1)$$

donde $f_{\theta} : \mathcal{V} \rightarrow \mathcal{L}$ es una función de parámetros θ que clasifica cada voxel $\mathcal{I}^{(i)}$ de la imagen en la región correspondiente: $\hat{\mathcal{I}}^{(i)} \in \mathcal{L} = \cup_{k=0}^K \ell_k$, con ℓ_k un label particular. E.g. f_{θ} es una red neuronal cuyos pesos entrenables son θ . La Figura 2.7 muestra un diagrama esquemático para una tarea de una segmentación.

Adicionalmente, para cada paciente podemos considerar distintas secuencias de imágenes tomadas en diferentes momentos: $\{\mathcal{I}_t\}_{t=0}^T$. Estas secuencias son referidas como dataset longitudinal. En la Figura 2.8 mostramos un ejemplo de un dataset longitudinal para un paciente dado. Formalizamos entonces el problema de clasificación según criterio RANO de la siguiente manera:

Definición 2.3.2 (Clasificación RANO). Dado un paciente $i \in [1, \dots, N]$, con distintas imágenes MRI tomadas a distinto tiempo t (medidas en días o semanas): $\mathcal{I}_0, \dots, \mathcal{I}_T$, con sus respectivas segmentaciones dadas por una función $f : \mathcal{V} \rightarrow \mathcal{L}$, que devuelva la imagen segmentada con los regiones de interés (e.g.: enhancing tumor, necrosis, etc.). Consideramos $\mathcal{I}_0$ el estado del paciente previo a la resección e $\mathcal{I}_1$ el estado luego de la resección. Podemos clasificar cada imagen según el criterio RANO:

$$\mathcal{R} = \{\text{Stable disease, Partial response, Complete Response, Progressive disease}\}$$




Fig. 2.8: Longitudinal imaging of a brain tumor over a span of 49 weeks. The images show four different imaging modalities: CT1, T1, T2, and FLAIR, taken at various time points (0 days, 3 days, 13 weeks, 23 weeks, 45 weeks, and 49 weeks). Each row represents a different modality, and each column represents a different time point, illustrating the progression and changes in the tumor over time. Image taken from [3].

Esto es, existe una función $g : \mathcal{L} \rightarrow \mathcal{R}$ tal que:

$$g(f(\mathcal{I}_0)) = \text{Pre-operative} \quad (2.2)$$

$$g(f(\mathcal{I}_1)) = \text{Complete Resection} \quad (2.3)$$

$$g(f(\mathcal{I}_t)) = r \in \mathcal{R} \quad \forall t > 1 \quad (2.4)$$

En teoría, la función g es una función basada en reglas y determinada según criterios clínicos y tomando en cuenta las imágenes segmentadas de tiempos anteriores. Existen diversas formas de clasificar según RANO, según la versión del criterio, la decisión del neuroradiólogo y las condiciones clínicas del paciente.

Para simplificar este proceso, nuestro criterio RANO estará basada en clasificar la diferencia volumétrica para cada par de tiempo. Para ello, nos bastará tomar la imagen segmentada $\mathcal{I}_{t,\text{seg}}$ y calcular el volumen de la región de interés ℓ_k para el tiempo t :

$$\text{Vol}_k(\mathcal{I}_{\text{seg}}) = \sum_{x \in \Omega} \mathbb{1}_{\{\mathcal{I}_{\text{seg}} = \ell_k\}}(x) \quad (2.5)$$

Esto es, para cada región de interés calcular el volumen (o su proporción) contando la cantidades de voxels de esa determinada región. Referimos al lector a la sección 3.4 para más detalles sobre la implementación.

2.3.2. Métodos basados en aprendizaje supervisado

En el contexto de nuestra tesis, seguiremos el marco del aprendizaje supervisado. En este marco, dados conjuntos de datos pre-etiquetados $\mathcal{D} = \{\mathbf{x}, y\}$, nuestro objetivo es aprender una función de mapeo f , utilizando solo los datos de entrenamiento (un subconjunto de nuestro conjunto de datos $\mathcal{D}_{train} \subset \mathcal{D}$ utilizado para estimar nuestros parámetros θ) de modo que pueda clasificar correctamente los elementos de nuestros conjuntos de prueba. Estos métodos requieren conocer las etiquetas de referencia: $\{y_i\}$. En el contexto de la segmentación de imágenes cerebrales, nuestras etiquetas a menudo se adquieren mediante segmentaciones manuales realizadas por expertos médicos. Muchas instituciones han invertido en crear segmentaciones de referencia fiables para poder entrenar y probar algoritmos de segmentación.

Segmentación basada en Deep Learning: se refiere a métodos que modelan nuestro clasificador f_θ como una red neuronal. Una red neuronal profunda básica consta de múltiples capas de neuronas interconectadas, donde cada neurona calcula una suma ponderada de sus entradas, aplica una función de activación no lineal y pasa el resultado a la siguiente capa. Los componentes clave de una red neuronal profunda incluyen la capa de entrada, las capas ocultas y la capa de salida. La **capa de entrada** es la primera capa que recibe los datos de entrada; para la segmentación de imágenes, podrían ser los valores de los píxeles de la imagen de entrada.

Las **capas ocultas** son las capas intermedias en una red neuronal que realizan cálculos sobre los datos. Cada capa oculta consta de neuronas que aplican pesos y sesgos aprendidos a las entradas, seguidos de una función de activación como ReLU, sigmoide o tanh, que introduce no linealidad en el modelo. Estas capas son cruciales para aprender representaciones complejas de los datos, permitiendo que la red capture patrones y características intrincadas que son esenciales para una segmentación precisa [17, 18].

La **capa de salida** es la capa final de la red que produce la salida. En el contexto de la segmentación, la capa de salida típicamente utiliza una función de activación softmax para asignar una probabilidad a cada píxel de pertenecer a una clase particular. La Figura 2.9 proporciona un diagrama de una red neuronal para una tarea de clasificación.

La salida probabilística permite que el modelo haga predicciones precisas sobre la segmentación de la imagen de entrada, identificando diferentes regiones u objetos dentro de la imagen. Los métodos de segmentación basados en deep learning aprovechan las capacidades de extracción de features de las redes neuronales para lograr alta precisión y robustez en varias tareas de imagen médica.

Las redes neuronales convolucionales (CNNs) son redes neuronales especializadas diseñadas para procesar estructuras de datos en forma de cuadrícula, como las imágenes. Las CNNs han revolucionado el procesamiento y análisis de imágenes, particularmente en la segmentación de imágenes, debido a su capacidad para aprender automáticamente y de manera adaptativa las jerarquías espaciales de características a partir de imágenes de entrada [20]. La arquitectura de las CNNs consiste en capas convolucionales, capas de pooling y capas fully-connected, cada una tiene una función específica en el proceso de extracción de características y análisis de imágenes. Véase la Figura 2.10.

Las **capas convolucionales** aplican filtros a los datos de entrada para extraer características relevantes. Una convolución es una operación matemática que toma dos funciones y produce una tercera función como resultado.




Fig. 2.9: Representación esquemática de una red neuronal feedforward para clasificación binaria. La red consta de una capa de entrada, múltiples capas ocultas y una capa de salida. La capa de entrada recibe los datos iniciales, que luego se pasan a través de las capas ocultas. Cada capa oculta está compuesta por neuronas, y las capas están completamente conectadas, lo que significa que cada neurona en una capa está conectada a cada neurona en la capa subsiguiente. Las capas ocultas son donde la red realiza cálculos complejos a través de conexiones ponderadas y funciones de activación, lo que permite que la red aprenda y extraiga características de los datos de entrada. La capa de salida proporciona la predicción final o resultado de la clasificación basado en las características aprendidas. Imagen tomada de [19]




Fig. 2.10: Ejemplo de una CNN. Imagen tomada de [21]

Definición 2.3.3. Dada una imagen de entrada I y un filtro (o kernel) K , la operación de convolución⁹ se define como:

$$(I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \cdot K(m, n)$$

donde $*$ denota la operación de convolución, y los índices m y n recorren la altura y el ancho del filtro K .

En la práctica, el filtro K se desliza sobre la imagen de entrada I , calculando una suma ponderada de los valores de píxel dentro de su campo receptivo. Esta operación transforma la imagen de entrada en un feature map (mapa de características), destacando la presencia de características específicas como bordes, líneas y texturas. La capa convolucional suele ir seguida de una función de activación, comúnmente ReLU: $\text{ReLU}(x) = \max(0, x)$.

Las **capas de pooling** realizan un submuestreo o reducción de muestreo de los feature maps para reducir las dimensiones espaciales y la complejidad computacional, al tiempo que retienen información importante. Los tipos más comunes de agrupamiento son el max pooling y el mean pooling

Definición 2.3.4. El max pooling se define como:

$$\text{MaxPooling}(I)(i, j) = \max_{m, n} I(i + m, j + n)$$

donde I es el feature map de entrada, y m y n son índices dentro de la ventana de agrupamiento.

Definición 2.3.5. El mean o average pooling se define como:

$$\text{AveragePooling}(I)(i, j) = \frac{1}{|W|} \sum_{(m, n) \in W} I(i + m, j + n)$$

donde W es la ventana de pooling, y $|W|$ es el número de elementos en W .

Las operaciones de pooling ayudan a hacer la detección de características invariante a pequeñas traslaciones y rotaciones de la imagen, lo que mejora el reconocimiento de objetos y reduce la probabilidad de sobreajuste.

Las **capas fully connected**, también conocidas como capas densas, se encuentran al final de la CNN. Estas capas tienen como objetivo aprender representaciones de alto nivel y abstractas al combinar todas las características extraídas. En las capas completamente conectadas, cada neurona está conectada a todas las neuronas de la capa anterior, lo que permite que la red integre información de todas las ubicaciones en los mapas de características. Estas capas desempeñan un papel crítico en las tareas de clasificación, interpretando las características agregadas para producir la salida final, como etiquetas de clase en la clasificación de imágenes o regiones segmentadas en la segmentación de imágenes.

Una red **fully convolutional (FCN)** es un tipo de CNN donde las capas completamente conectadas finales son reemplazadas por capas convolucionales. Esto permite que

⁹ En términos técnicos, esto corresponde a la correlación. Para la convolución, sustituimos el signo $+$ por $-$. No obstante, tradicionalmente, esta operación se ha denominado convolución.

la red tome imágenes de entrada de cualquier tamaño y produzca features maps de salida con dimensiones espaciales correspondientes.

Las FCNs permiten el aprendizaje y la predicción de extremo a extremo en imágenes al mantener jerarquías espaciales a lo largo de la red, permitiendo predicciones densas donde cada píxel en la imagen de entrada se asigna a una etiqueta de clase. Esta capacidad es esencial para tareas como la segmentación de imágenes, donde la relación espacial entre la entrada y la salida es crucial para una delineación precisa y exacta de las estructuras anatómicas.

U-Net [22] es una FCN específicamente diseñada para la segmentación de imágenes biomédicas. Su innovación clave es la arquitectura simétrica encoder-decoder, que permite tanto la captura de características abstractas de alto nivel como la localización precisa de estas características en la imagen de entrada. La ruta del encoder captura el contexto de la imagen al reducir progresivamente la muestra de entrada mediante la aplicación repetida de convoluciones, activaciones ReLU y max pooling. Esto reduce las dimensiones espaciales mientras aumenta la profundidad de los mapas de características, permitiendo a la red aprender características complejas en múltiples escalas.

La ruta del decoder reconstruye las dimensiones espaciales aumentando la muestra de los features maps utilizando convoluciones transpuestas. Las convoluciones transpuestas revierten la reducción de muestra realizada en el encoder aumentando la resolución espacial de los features maps. Esta ruta se complementa con skip connections que enlazan directamente las capas correspondientes del encoder y el decoder. Las skip connections ayudan a retener la información espacial detallada que podría perderse durante la reducción de muestra, permitiendo a la red combinar características detalladas y de alta resolución del encoder con las características aumentadas en el decoder. Esta combinación mejora la capacidad de la red para delinear con precisión estructuras complejas dentro de las imágenes, haciendo que U-Net sea particularmente adecuada para tareas de imágenes médicas que requieren segmentación precisa (cf. Figura 2.11).




Fig. 2.11: Arquitectura de UNet. Imagen tomada de [22].

Entrenamiento de la red. Todos los modelos de deep learning implican ajustar sus parámetros (pesos y sesgos) para que el modelo pueda hacer predicciones precisas. Este

proceso se guía por el concepto de función de pérdida, que mide qué tan bien las predicciones del modelo coinciden con los valores verdaderos. El objetivo del entrenamiento es minimizar esta función de pérdida. La **función de pérdida** cuantifica la diferencia entre la salida predicha y la salida verdadera. Existe una amplia gama de funciones de pérdida para elegir dependiendo de las tareas a resolver. Por ejemplo, la pérdida de entropía cruzada se utiliza ampliamente para problemas de clasificación, y mide el rendimiento de un modelo de clasificación cuya salida es un valor de probabilidad entre 0 y 1. Dada una etiqueta verdadera y y una probabilidad predicha $\hat{y}$, la pérdida de entropía cruzada binaria se define como:

$$\mathcal{L}_{\text{BCE}}(y, \hat{y}) = -[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})] \quad (2.6)$$

El proceso de entrenamiento se realiza típicamente utilizando un algoritmo de optimización llamado **descenso de gradiente estocástico (SGD)**. SGD es una variación del algoritmo de descenso de gradiente, que ajusta iterativamente los parámetros del modelo en la dirección que reduce la pérdida. Dada una tasa de aprendizaje η , la regla de actualización para los pesos W utilizando descenso de gradiente es:

$$W := W - \eta \nabla_W \mathcal{L}(W) \quad (2.7)$$

donde $\nabla_W \mathcal{L}(W)$ es el gradiente de la función de pérdida con respecto a los pesos.

En el descenso de gradiente estocástico, en lugar de calcular el gradiente utilizando todo el conjunto de datos, el gradiente se aproxima utilizando un subconjunto seleccionado aleatoriamente (o mini-batch) de los datos. Esto acelera significativamente el proceso de entrenamiento e introduce un ruido beneficioso que puede ayudar al modelo a escapar de mínimos locales.

La regla de actualización para los pesos W utilizando descenso de gradiente estocástico es:

$$W := W - \eta \nabla_W \mathcal{L}(W; \mathbf{X}_i, \mathbf{y}_i) \quad (2.8)$$

donde $(\mathbf{X}_i, \mathbf{y}_i)$ representa un mini-batch de los datos de entrenamiento.

Backpropagation es el algoritmo utilizado para calcular el gradiente de la función de pérdida con respecto a cada peso aplicando la regla de la cadena. Esto implica dos pasadas a través de la red: una pasada hacia adelante para calcular las predicciones y la pérdida, y una pasada hacia atrás para calcular los gradientes.

Un **epoch** se refiere a una pasada completa a través de todo el conjunto de datos de entrenamiento. Durante cada epoch, los parámetros del modelo se actualizan múltiples veces (una por mini-batch). El número de iteraciones por epoch es igual al número de muestras de entrenamiento dividido por el tamaño del mini-batch. El entrenamiento típicamente involucra múltiples epochs hasta que la función de pérdida converge o deja de mejorar.

Finalmente, presentamos el modelo utilizado en nuestra tesis: **nnU-Net** es un framework de deep learning autoconfigurable diseñado para la segmentación de imágenes médicas, que evoluciona a partir de la arquitectura U-Net básica [5]. El nombre “nnU-Net” proviene del concepto de no utilizar una nueva U-Net (“no-new U-Net”), enfatizando que este framework no introduce cambios arquitectónicos novedosos, como mecanismos de self-attention, sino que se centra en un marco robusto capaz de adaptarse a diversos conjuntos de datos.

Este método maneja también parte del preprocesamiento, la arquitectura de la red, el entrenamiento y el post-procesamiento para cualquier nueva tarea. La configuración

automática de nnU-Net se basa en la destilación del conocimiento del dominio en tres grupos de parámetros: parámetros fijos, basados en reglas y empíricos.

El proceso comienza con la extracción del 'dataset fingerprint' (huella digital del conjunto de datos), que incluye propiedades clave como los espaciamientos de vóxeles, las dimensiones de la imagen, las distribuciones de intensidad y la modalidad de imagen. Estas características informan los 'rule-based parameters' (parámetros basados en reglas), donde se establecen dependencias entre el dataset fingerprint y la configuración del pipeline. Los parámetros basados en reglas incluyen estrategias para el remuestreo, el espaciamiento objetivo, los tamaños de parche y batch, la memoria del GPU y la topología de la red, asegurando que el framework se adapte de manera óptima a cada nueva tarea. Los 'fixed parameters' (parámetros fijos), que no requieren adaptación específica del conjunto de datos, abarcan elementos como el optimizador, procedimientos de entrenamiento e inferencia, la plantilla de arquitectura de tipo U-Net, y los procesos de data augmentation (esto consiste en generar artificialmente datos nuevos a partir de los ya existentes, mediante rotación, flippeado, etc.). Además, los 'empirical parameters' (parámetros empíricos) implican la selección del ensamble y las configuraciones de postprocesamiento para mejorar la salida final de la segmentación.




Fig. 2.12: Diagrama de nnU-Net. Dada una nueva tarea de segmentación, se extraen las propiedades del conjunto de datos en forma de una 'dataset fingerprint' (rosa). Un conjunto de reglas heurísticas modela las interdependencias de los parámetros (mostradas como flechas delgadas) y opera sobre esta huella digital para inferir los 'rule-based parameters' (verde) del pipeline. Estos se complementan con 'fixed parameters' (azul), que están predefinidos y no requieren adaptación. Se entrenan hasta tres configuraciones en una validación cruzada de cinco folds. Finalmente, nnU-Net realiza automáticamente la selección empírica del mejor conjunto de estos modelos y determina si se requiere post-procesamiento ('empirical parameters', amarillo). Imagen tomada de [6].

nnU-Net es el primer framework totalmente automático para la segmentación biomédica. Consiste en tres configuraciones de pipeline distintas: U-Net 2D para segmentar cortes 2D, U-Net 3D para manejar volúmenes 3D y un U-Net 3D en cascada para segmentar imágenes de alta resolución mediante un proceso de dos etapas que implica la reducción de muestra y el finetuning. Estos pipelines se construyen sobre varias capas de convolución

y deconvolución con skip connections de la arquitectura U-Net clásica.

Desde una perspectiva práctica, nnU-Net simplifica el flujo de trabajo para la segmentación de imágenes médicas. Los usuarios solo necesitan formatear sus datos según los requisitos del framework, después de lo cual nnU-Net maneja automáticamente los procesos de configuración y entrenamiento. Esta estrategia robusta ha demostrado superar soluciones altamente especializadas en 23 conjuntos de datos públicos utilizados en competencias internacionales de segmentación biomédica (Decatlón de Segmentación Médica). El enfoque estandarizado de nnU-Net también promueve la reproducibilidad en la investigación, ya que se puede aplicar consistentemente a diferentes conjuntos de datos y tareas, logrando un rendimiento de vanguardia [23]. La Figura 2.12 presenta una visión general esquemática del marco nnUNet tomada del artículo [6].

2.3.3. Trabajos relacionados

Existen métodos que no utilizan deep learning, algunos se basan en modelar el crecimiento del tumor o en realizar extracción de características de los datos de imágenes cerebrales, siguiendo el framework de aprendizaje automático clásico. Además, hay métodos no supervisados para la segmentación de tumores que no dependen de la segmentación de referencia. Para una revisión completa sobre estos temas, consulte [24, 25].

Por último, en [2] se revisan más de 100 artículos científicos sobre segmentación de tumores cerebrales utilizando deep learning, destacando arquitecturas de red como CNNs, FCNs y modelos basados en Transformers como [26, 27]. Los modelos nuevos abordan desafíos significativos como el desequilibrio de datos con técnicas como el cambio de la función de pérdida, en el diseño de arquitectura o la fusión de múltiples modalidades. El survey también identifica direcciones futuras de investigación, incluyendo mejorar la interpretabilidad del modelo, cómo inputar datos faltantes y aprovechar el conocimiento del dominio para un mejor rendimiento.

3. DESAROLLO Y METODOLOGÍA

En este capítulo explicamos las metodologías usadas en los diversos experimentos que realizamos. En la sección 3.1 explicamos los métodos de preprocesamientos realizados previo a la segmentación. La sección 3.2 detalla las métricas usadas para evaluar los modelos. Luego, nos centramos primero en el problema de segmentación de tumores (3.3): presentamos los experimentos realizados para determinar el mejor modelo de segmentación para nuestra tarea y discutimos los resultados. Una vez obtenido el modelo, pasamos a la siguiente etapa (3.4): la clasificación según RANO en un dataset longitudinal.

3.1. Preprocesamiento

Nos referiremos al preprocesamiento como cualquier método aplicado antes de que los datos se ingresen a un modelo de segmentación. En la siguiente sección, proporcionamos una breve descripción de los métodos utilizados en esta tesis.

El preprocesamiento es un paso crucial en el análisis de imágenes cerebrales, ya que garantiza la calidad y consistencia de las imágenes utilizadas para las tareas de análisis posteriores. Los pasos comunes de preprocesamiento incluyen la normalización y estandarización, que ajustan los valores de intensidad y los formatos de las imágenes a una escala común; la eliminación del cráneo y la extracción del cerebro (skull-stripping), que eliminan los tejidos no cerebrales para centrarse en la región de interés; la corrección del campo de sesgo, que aborda las inhomogeneidades de intensidad; y el coregistro de imágenes, que alinea las imágenes de diferentes modalidades o puntos temporales para garantizar la consistencia espacial.

Formato de archivos. DICOM (Digital Imaging and Communications in Medicine) y NIfTI (Neuroimaging Informatics Technology Initiative) son dos formatos de imagen principales utilizados en la imagen médica. Los datos de imagen en bruto de un escáner de RM generalmente vienen en formato DICOM, que también es el estándar internacional para transmitir, almacenar y mostrar información de imágenes médicas, garantizando la interoperabilidad entre varios dispositivos médicos. Incluye metadata completas, como información del paciente y parámetros de adquisición de imágenes, lo que lo hace indispensable en entornos clínicos. Por otro lado, NIfTI (.nii o .nii.gz) está específicamente diseñado para datos de neuroimágenes como escaneos de MRI y fMRI. Su simplicidad y eficiencia, sobre la complejidad del sistema de archivos DICOM, lo convierten en el formato preferido en la investigación de neuroimágenes, permitiendo una manipulación y análisis fáciles de los datos de imagen.

La visualización y segmentación de imágenes médicas son críticas para un diagnóstico preciso y la investigación. En esta tesis usamos ITK-SNAP [28], que es una herramienta de software ampliamente utilizada que admite formatos DICOM y NIfTI, proporciona funciones avanzadas como soporte multimodal de las imágenes y renderizado de volumen en 3D.

Usamos dcm2niix (<https://github.com/rordenlab/dcm2niix>) para convertir imágenes DICOM a formato NIfTI. También usamos NiBabel [29], una biblioteca de Python, que proporciona acceso de lectura y escritura a varios formatos de datos de neuroimágenes,

facilitando tareas de preprocesamiento como la normalización y visualización. Además, usamos FSL (FMRIB Software Library) [30] que ofrece un conjunto de herramientas para preprocesamiento y análisis, incluyendo extracción del cerebro y registro de imágenes.

Métodos de preprocesamiento

Coregistración

Alinear múltiples imágenes del mismo sujeto es un paso crítico para un análisis preciso. Este proceso de alineación, conocido como coregistración de imágenes, asegura que las imágenes se muestren en un sistema de coordenadas común, resultando en un conjunto de imágenes alineadas. Este paso es esencial para extraer información significativa de múltiples modalidades de imagen o de estudios longitudinales donde se toman escaneos en diferentes momentos.

Durante el proceso de coregistración, una imagen (la imagen flotante) se alinea con una imagen de referencia (la imagen fija). Existen diferentes tipos de métodos de registro basados en las transformaciones aplicadas:

- **coregistración rígida:** la imagen flotante solo puede ser traducida y rotada para alinearse con la imagen de referencia. Este método implica seis grados de libertad en 3D (tres para la traslación y tres para la rotación).
- **coregistración afín:** además de la traslación y rotación, la imagen flotante también puede ser escalada y cortada. Este método implica doce grados de libertad en 3D, representados por una matriz de transformación afín.
- **coregistración no rígida:** también conocido como coregistración deformable o elástica, este método captura deformaciones locales y se define por un campo de deformación. A diferencia de la coregistración rígida y afín, este puede tener en cuenta cambios complejos y localizados en la forma. Sin embargo, es computacionalmente más intensivo y puede alterar estructuras críticas si no se aplica cuidadosamente.

Coregistro de imágenes multimodales Coregistrar imágenes de diferentes modalidades (p. ej., T1, T1c, T2, FLAIR) es una práctica común. La coregistración afín se utiliza típicamente para este propósito, ya que preserva la estructura general mientras permite los ajustes necesarios en escala y orientación. La coregistración no rígida generalmente se desaconseja porque puede introducir deformaciones locales que alteran la forma del tumor y las estructuras del tejido cerebral. En su lugar, todas las modalidades pueden registrarse a un espacio de referencia común, como el MNI 152 ¹, asegurando consistencia entre conjuntos de datos.

Esta técnica de preprocesamiento se usa generalmente para los siguientes casos:

- **Coregistración Monomodal Intra-paciente:** Utilizado para el seguimiento temporal, comparando escaneos del mismo paciente a lo largo del tiempo para monitorear la progresión de la enfermedad o la respuesta al tratamiento.
- **Coregistración Multimodal:** Alineación de diferentes modalidades de imagen para combinar información estructural y funcional, lo cual es esencial para un análisis integral.

¹ Es un cerebro promedio tomado de MRI de 152 individuos sanos.

- **Coregistración Inter-paciente:** Utilizado en la construcción de atlas y estudios de población, alineando escaneos individuales a un atlas cerebral estandarizado para estudios comparativos.

El proceso de coregistración tiene como objetivo encontrar la transformación óptima que minimice las diferencias entre las imágenes flotantes y de referencia. Esto implica optimizar un criterio de similitud, como la información mutua o la correlación cruzada normalizada. El modelo de transformación elegido, ya sea rígido, afín o no rígido, dicta la complejidad computacional y la precisión de la alineación. Herramientas como Advanced Normalization Tools (ANTs) y FSL (usado en esta tesis) proporcionan implementaciones para realizar la coregistración de imágenes.

Re-muestreo

El re-muestreo de imágenes implica modificar la resolución espacial de una imagen. Diferentes máquinas y protocolos clínicos pueden resultar en imágenes de diferentes tamaños y, por lo tanto, es necesario re-muestrear las imágenes. Esto asegura que todas las imágenes cumplan con una resolución común. El re-muestreo ajusta los datos de la imagen para que coincidan con una cuadrícula de vóxeles deseada, permitiendo una comparación, análisis e integración de las imágenes más precisos. Este redimensionamiento simplemente consiste en aumentar o reducir la cuadrícula de imagen 3D. Esto implica interpolar los datos de la imagen para ajustarlos a una nueva cuadrícula de vóxeles. Hay varios métodos de interpolación comúnmente utilizados en la imagen médica: Nearest Neighbor Interpolation, que asigna el valor del vóxel más cercano a cada nuevo vóxel; Linear Interpolation, que utiliza un promedio ponderado de los vóxeles circundantes para calcular nuevos valores de vóxel; y la interpolación por B-Spline, que utiliza B-splines para interpolar los valores de los vóxeles, ofreciendo mayor precisión a expensas de un mayor costo computacional.

Este proceso generalmente se necesita cuando los datos deben ser isotrópicos, lo que significa que el espaciamiento de los píxeles debe ser idéntico en todas las direcciones (a lo largo de los ejes x, y, z). En esta tesis, usamos la función `conform` de la biblioteca NiBabel [29].

Eliminación del cráneo

La eliminación del cráneo (skull-stripping) implica eliminar tejidos extraños como el cráneo, los ojos y otras estructuras no cerebrales de las imágenes de MRI. Este paso de preprocesamiento se enfoca únicamente en los tejidos cerebrales: materia gris (GM), materia blanca (WM) y líquido cefalorraquídeo (CSF), que son críticos para analizar tumores cerebrales y otras condiciones neurológicas.

Este proceso no altera los datos de la imagen en bruto, pero simplifica significativamente las tareas de análisis posteriores. En la segmentación o clasificación de tumores, las estructuras no cerebrales pueden introducir ruido o errores, haciéndolas irrelevantes desde una perspectiva de aprendizaje automático. Por lo tanto, la eliminación del cráneo es esencial para mejorar la precisión y el enfoque de las regiones de interés en las imágenes de MRI.

Existen varios métodos de eliminación del cráneo disponibles. Un método ampliamente utilizado es el algoritmo ROBEX (Robust Brain Extraction) [31], conocido por su eficiencia y efectividad, particularmente en imágenes ponderadas en T1 ce. Otra herramienta

utilizada es BET, proporcionadas por FSL [30]. Aunque estas herramientas generalmente funcionan bien, pueden producir resultados subóptimos en imágenes que contienen tumores cerebrales debido a las formas y ubicaciones irregulares de estos. En tales casos, puede ser necesaria la inspección visual y el ajuste manual para garantizar la precisión. Sin embargo, para esta tesis, se consideraron suficientes los métodos automatizados.

La eliminación del cráneo es integral para preparar las imágenes de MRI para un procesamiento adicional, asegurando que las tareas de aprendizaje automático y análisis se realicen sobre datos limpios y relevantes. Todas las imágenes cerebrales presentadas en esta tesis han pasado por la eliminación del cráneo usando ROBEX.

Normalización de intensidad

Durante la adquisición de imágenes por RM, se pueden utilizar diferentes escáneres o parámetros para escanear a diferentes sujetos o al mismo sujeto en diferentes momentos, lo que conduce a variaciones significativas de intensidad. Estas variaciones de intensidad pueden empeorar el rendimiento de la tarea de segmentación.

La mayoría de los métodos de segmentación y clasificación de imágenes se basan en las intensidades de los vóxeles y suponen una distribución de intensidad estandarizada en las imágenes de RM. Por ejemplo, muchos algoritmos requieren que las imágenes tengan un rango de intensidad estandarizado. Por lo tanto, la normalización de la intensidad es una parte crucial de la línea de preprocesamiento. Este proceso implica normalizar, escalar o alinear las distribuciones de intensidad en diferentes imágenes de RM para garantizar la consistencia en análisis posteriores.

Reescalado de intensidad. Un enfoque común para la normalización de intensidad es el reescalado de intensidad, donde las intensidades de los vóxeles se ajustan para encajar dentro de un rango especificado, a menudo $[0, 1]$ o $[0, 255]$. Este método asegura que todas las imágenes tengan un rango de intensidad consistente, facilitando una mejor comparación y análisis.

$$I_{rescaled}(x) = \frac{I(x) - I_{\min}}{I_{\max} - I_{\min}}$$

Z-normalización. Otro método efectivo para la normalización de intensidad es la normalización a $Z \sim \mathcal{N}(0, 1)$, que estandariza las intensidades de los vóxeles para tener una media de cero y una desviación estándar de uno. Esta transformación es particularmente útil para análisis estadísticos y algoritmos de aprendizaje automático que suponen datos distribuidos normalmente. La transformación z se realiza utilizando la siguiente ecuación:

$$I_z(x) = \frac{I(x) - \mu_I}{\sigma_I}$$

3.2. Métricas

Las métricas de evaluación son esenciales para evaluar el rendimiento del modelo y su ajuste a los datos. El objetivo es medir la similitud entre la segmentación predicha (predicción) y la segmentación verdadera (ground truth). En esta sección, discutimos dos métricas de validación utilizadas para evaluar nuestros modelos a lo largo de esta tesis: Dice score y la distancia de Hausdorff. Si bien el desarrollo de métricas de evaluación es un

área de investigación abierta, estas dos métricas son ampliamente empleadas en el dominio de la segmentación de imágenes cerebrales.

El Dice score, también conocida como F1 en el aprendizaje automático clásico, mide la superposición voxel a voxel entre las segmentaciones predichas y la ground truth. Se define como sigue:

Definición 3.2.1 (Dice score). Para cada clase de interés $k \in K$ (por ejemplo, una etiqueta o región tumoral específica), el Dice score para la etiqueta k se puede calcular como:

$$\text{Dice}(A, B) = \frac{2 \text{ TP}}{2 \text{ TP} + \text{FP} + \text{FN}} \quad (3.1)$$

$$= \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} \quad (3.2)$$

$$= \frac{2|A \cap B|}{|A| + |B|} \quad (3.3)$$

donde TP son los verdaderos positivos, FP son los falsos positivos, FN son los falsos negativos. La precisión es el ratio de verdaderos positivos sobre la suma de verdaderos positivos y falsos positivos, y el recall es el ratio de verdaderos positivos sobre la suma de verdaderos positivos y falsos negativos. Aquí, $A = \mathbf{1}\{f(\mathcal{I}) = k\}$ es el mapa de segmentación predicho y B es el mapa de segmentación ground truth para una clase dada k .

Debido a que el Dice score mide la superposición voxel a voxel, puede devolver valores bajos para estructuras pequeñas, incluso si se parecen mucho a la verdadera.

Definición 3.2.2 (Distancia de Hausdorff). La distancia de Hausdorff cuantifica la distancia de la superficie en lugar de la superposición voxel a voxel. Se define como la distancia máxima entre cualquier punto a en el conjunto A y el punto más cercano b en el conjunto B :

$$\text{Hd}(A, B) = \max \left\{ \sup_{a \in A} \inf_{b \in B} d(a, b), \sup_{b \in B} \inf_{a \in A} d(b, a) \right\} \quad (3.4)$$

donde $d(a, b)$ es la distancia entre los puntos a y b .

La distancia de Hausdorff es particularmente útil para evaluar la precisión general de la segmentación, especialmente la delineación del contorno. En esta tesis, calculamos en realidad la distancia de Hausdorff de percentil 95 (HD95). A diferencia de la distancia de Hausdorff estándar, que mide la distancia máxima entre cualquier punto en un contorno y el punto más cercano en el otro contorno, la HD95 se enfoca en el percentil 95 de estas distancias. Esto la hace menos sensible a valores atípicos y proporciona una medida más estable y representativa de la alineación. Esta métrica se puede calcular de la siguiente manera:

1. Calcular todas las distancias punto a punto: para cada punto en el contorno predicho, calcular la distancia al punto más cercano en el contorno de ground truth, y viceversa.
2. Ordenar las distancias en orden ascendente.
3. Seleccionar la distancia del percentil 95: identificar el valor de la distancia por debajo del cual caen el 95 % de las distancias calculadas.

Para una revisión completa de las métricas de evaluación, consulte [32, 33].

Nota sobre las anotaciones Observamos que las métricas mencionadas anteriormente siempre consideran la existencia de mapas de segmentación de referencia. Pero estas segmentaciones generalmente son realizados por anotadores humanos y pueden estar sujetos a sesgos personales o incluso a desacuerdos entre los anotadores. Además, debido a la naturaleza 3D del problema, también puede dificultar la tarea de etiquetado. Existen métodos (no usadas en esta tesis) que pueden detectar el sesgo y realizar la correcciones [34, 35].

Datasets

BraTS

BraTS corresponde al benchmark más usado en el área de segmentación de tumores, fue propuesto en el 2012 como parte de desafíos anuales de MICCAI (Medical Image Computing and Computer-Assisted Intervention). Los datos vienen separados en: entrenamiento (train), validación (val) y evaluación (evaluation). Son imágenes de MRI en formato Nifti. Los datos de BraTS en los que nos centraremos consisten en BraTS 2020 y BraTS 2021 [1, 36, 37, 38, 39]. Estos conjuntos de datos son ampliamente utilizados para el entrenamiento y la evaluación de algoritmos de segmentación de tumores cerebrales debido a la calidad y cantidad de sus anotaciones realizadas por expertos.

El conjunto de datos BraTS 2020 comprende 369 casos de entrenamiento y 125 casos de validación, cada uno incluyendo imágenes multimodales de MRI (T1, T1c, T2 y FLAIR) junto con anotaciones expertas de las regiones del tumor, que abarcan necrosis y non-enhancing, edema peritumoral y enhancing tumor. El conjunto de datos incluye escaneos MRI preoperatorios de múltiples instituciones, capturados con diferentes escáneres y protocolos, lo que introduce una variedad de artefactos y patrones de ruido, reflejando escenarios clínicos del mundo real.

BraTS 2021 amplió el conjunto de datos, ofreciendo 1251 casos de entrenamiento, proporcionando así un conjunto de imágenes MRI aún más grande y diverso para el entrenamiento de modelos de deep learning. El conjunto de datos incluye las mismas secuencias de MRI multimodales y anotaciones expertas, manteniendo la consistencia con versiones anteriores mientras aumenta la cantidad de datos disponibles para desarrollar modelos de segmentación más precisos y fiables. El mayor tamaño del conjunto de datos ayuda a capturar más variabilidad en la morfología del tumor y la demografía de los pacientes, mejorando la capacidad del modelo para generalizar a datos nuevos y no vistos.

FLENI

Los datos que denominaremos FLENI consisten en datos provistos por el hospital FLENI (Argentina). Este conjunto de datos incluye 21 datos de pacientes clasificados como glioma de alto grado (HGG) y 20 datos de pacientes clasificados como glioma de bajo grado (LGG). Dado que necesitamos las 4 modalidades para poder segmentar, de estos pacientes terminando tomando las siguientes cantidades: 18 con glioma alto y 13 con glioma bajo, excluyendo aquellos que les faltaban algunas de las modalidades.

Cabe destacar que estos datos son consistentes en cuanto a la modalidad y labels de segmentación con los datos de BraTS, lo cual facilita la integración y comparación de los resultados obtenidos en diferentes experimentos. La coherencia en las modalidades de

imagen utilizadas permite aplicar las mismas técnicas de preprocesamiento y segmentación desarrolladas para los datos de BraTS a los datos de FLENI.

LUMIERE

El conjunto de datos que denominamos Lumiere consiste en un conjunto longitudinal de imágenes de resonancia magnética (MRI) de 91 pacientes con glioblastoma, recopilado como parte de un estudio detallado y disponible en [3]. Este conjunto de datos incluye un total de 638 fechas de estudio y 2487 imágenes MRI multimodales (T1, T1ce, T2 y FLAIR) tomadas en diferentes puntos temporales, permitiendo el seguimiento de la progresión o regresión del tumor a lo largo del tiempo. Las imágenes en la serie longitudinal están anotadas por expertos según las guías de evaluación de respuesta en neuro-oncología (RANO). Además, el conjunto de datos incluye segmentaciones automáticas de DeepBraTumIA (<https://www.nitrc.org/projects/deepbratumia/>) y HD-GLIO-AUTO [40, 41, 5]. Compararemos nuestros resultados con las etiquetas dadas por DeepBraTumIA, que proporcionan etiquetas para necrosis y non-enhancing, enhancing tumor y edema. Este conjunto de datos es esencial para el estudio de la progresión de la enfermedad según los criterios RANO, proporcionando una visión más completa de cómo los tumores evolucionan y responden a las intervenciones terapéuticas.

3.3. Segmentación de tumores

En esta sección, describimos la metodología empleada para desarrollar un modelo de segmentación de tumores cerebrales. Optamos por el transfer learning debido a las limitaciones en el tamaño de nuestro dataset y la capacidad de cómputo. Este enfoque consiste en tomar un modelo preentrenado en un conjunto de datos similar y continuar su entrenamiento con nuestro conjunto de datos objetivo, lo que nos permite mejorar la eficiencia y efectividad del modelo en nuestra aplicación específica. Más específicamente, utilizamos un modelo nnU-Net preentrenado en el conjunto de datos BraTS2020 para establecer un baseline. Luego, finetuneamos este modelo con el dataset de FLENI para mejorar el rendimiento en este dataset.

Los pasos clave en nuestra metodología son los siguientes:

1. Preparación del conjunto de datos
2. Evaluación del modelo baseline
3. Finetuning del modelo
4. Evaluación del rendimiento
5. Iterar

3.3.1. Experimento 1: Baseline

Modelo: Elegimos emplear la arquitectura nnU-Net preentrenada datos BRATS2020 [5] para nuestra tarea de segmentación, a este modelo lo denominaremos: **nnU-Net BL**. El proceso de entrenamiento con nnU-Net comienza con una fase de preprocesamiento donde las imágenes se normalizan y escalan para asegurar un tamaño y rango de intensidad uniformes en todas las imágenes, para las etiquetas se reescalan a la misma dimensión que las imágenes.

Evaluación baseline: Comenzamos evaluando el rendimiento del modelo nnU-Net preentrenado en los datos de BraTS2020 utilizando los datos BraTS 2021. Cabe destacar que hay filtrado de datos en esta evaluación, ya que hay datos de evaluación de BraTS 2021 que se usaron para entrenar el modelo. No obstante, este paso nos permite comprender el rendimiento de base del modelo y establecer un punto de referencia.

Preprocesamiento de datos de FLENI: Preprocesamos los datos FLENI, que consta de 13 muestras de gliomas de bajo grado (LGG) y 18 de gliomas de alto grado (HGG) para asegurar la consistencia con los datos de BraTS 2020:

1. Resamplero de datos: Usando la biblioteca NiBabel [29], las imágenes se reformatearon a volúmenes de 240x240x155 vóxeles con una resolución isotrópica de 1mm³.
2. Co-registro de imágenes: Las diferentes modalidades de MRI se registraron al espacio de la secuencia T1 con contraste (T1ce) utilizando la herramienta de registro lineal FLIRT [30].
3. Estandarización de headers: Los headers se estandarizaron a un origen común (0,0,0) y se eliminaron todas las transformaciones afines asociadas.
4. Extracción de cerebro: La extracción del cerebro se realizó utilizando la herramienta Robex [31] implementada en PyRobex.

Cabe notar que la normalización de intensidad se omite ya que es manejada inherentemente por el nnU-Net.

Entrenamiento del modelo: Para finetunear el modelo nnU-Net preentrenado con datos FLENI, dividimos primero este conjunto en datos de entrenamiento y prueba, utilizando un train-test split estratificado con una división 50/50. Luego, el modelo es entrenado durante 250 epochs utilizando dos GPUs T4 y 80 núcleos de CPU.

Framework de evaluación: Para evaluar nuestros modelos, tanto antes como después de entrenamiento, medimos su capacidad para segmentar tres regiones tumorales claves: edema, necrosis y non-enhancing tumor, y enhancing tumor. Informamos las métricas de Dice score y distancia de Hausdorff (Hd95). Esta evaluación proporciona información sobre la efectividad del modelo y áreas de posible mejora.

Evaluación 1: nnUNet preentrenado en Brats2020 evaluado en 2021




Fig. 3.1: Coeficiente de Dice y de Hausdorff para las imágenes del dataset Brats2021. Notar que las estimaciones son sobreoptimistas debido a que la base de datos Brats2021 contiene imágenes de la base de datos Brats2020 que fue utilizada durante el entrenamiento.

La Figura 3.1 incluye las evaluaciones obtenidas para la base de datos BRATS 2021, utilizando las métricas del Dice scores y la distancia de Hausdorff. El coeficiente de Dice mide la superposición entre las regiones de tumor predichas y las reales, donde valores más altos indican un mejor rendimiento de segmentación. La distancia de Hausdorff, que mide la precisión espacial de la segmentación, mientras más bajo, mejor.

Puede observarse que los valores de Dice cercano a 0.9 y de Hausdorff cercano a 10 píxeles son realmente muy prometedores. Asimismo, el modelo muestra consistencia en todos los casos, por el bajo IQR en ambas métricas. No obstante, notamos algunos outliers, indicativo de que aún se puede mejorar el modelo. Sin embargo, hay que tener en cuenta que estos resultados son sobre optimistas, porque una parte de los datos de BRATS 2021 corresponden a los de BRATS2020, por lo que dicha evaluación está sesgada y se espera que al ser utilizados en otras bases de datos el rendimiento disminuya.

Evaluación 2: nnUNet preentrenado en Brats2020 evaluado en los datos de test de FLENI




Fig. 3.2: Ejemplo de imágenes del dataset FLENI (1era columna), la correspondiente segmentación manual realizada por expertos radiólogos (2da columna) y la correspondiente segmentación automática generada por el modelo nnUNet. Las etiquetas corresponde a **edema** (rojo), **zona necrótica + non-enhancing tumor** (verde), **enhancing tumor** (azul).

Los resultados obtenidos al evaluar el modelo pre-entrenado en los datos de FLENI son variados. En la Figura 3.2 mostramos un ejemplo de segmentación, comparando visualmente la segmentación verdadera con la predicha. La Figura 3.3 incluye resultados para la base de datos FLENI. Como puede apreciarse, el rendimiento disminuye debido al domain shift. Esto es un fenómeno que aparece cuando la distribución de los datos de entrenamiento difiere de los datos en producción. En este caso, notamos una gran dispersión en las predicciones de edema y gran variabilidad en las otras predicciones. Mientras que para algunas predicciones funcionan bien, para otras no.




Fig. 3.3: Coeficiente de Dice (izq.) y de Hausdorff (der) para nn-UNet baseline evaluado en las imágenes del dataset FLENI (test).

Evaluación 3: nnUNet finetuneado en FLENI evaluado en los datos de test de FLENI






Fig. 3.4: Coeficiente de Dice y de Hausdorff para nnUNet finetuneado en las imágenes del dataset FLENI (test).

Finetuneamos el modelo **nnU-Net** BL usando los datos de FLENI para entrenar y reportamos el promedio y la mediana por clase para las métricas de evaluación en la Tabla 3.1. Al comprar la Figura 3.3 y la Figura 3.4, notamos que nuestro modelo no mejora. Para el caso de edema, obtenemos resultados similares tanto en Dice y Hausdorff. Un test de Wilcoxon para ambas métricas verifica esta afirmación ($p\text{-val}=0.21$ para Dice y $p\text{-val}=0.36$ para Hausdorff). Para necrosis y non-enhancing, observamos resultados similares ($p\text{-val}=0.30$ para Dice y $p\text{-val}=0.39$ para Hausdorff). En enhancing, notamos que

el modelo empeora ($p\text{-val}=0.02$ para Dice y $p\text{-val}=0.002$ para Hausdorff). Cabe destacar que la distribución de nuestros datos es imbalanceada: para los pacientes de glioma bajo, estos no presentan componente de edema, mientras que los datos de gliomas alto sí. En la Figura 3.5 mostramos el coeficiente de Dice pre y post entrenamiento, segregado por pacientes de glioma alto y bajo (HGG y LGG). Observamos cualitativamente que para la categoría necrosis y enhancing tumor, empeora en los casos de HGG y mejora en los casos de LGG. Para enhancing tumor, las predicciones son similares. En edema, hay una mejora en LGG y HGG.



(a) Dice scores pre y post entrenamiento. A la izquierda: coeficiente de Dice por clase previo al entrenamiento para pacientes de glioma alto (HGG). A la derecha: coeficiente de Dice por clase post entrenamiento para pacientes de glioma alto (HGG).



(b) Dice scores pre y post entrenamiento. A la izquierda: coeficiente de Dice por clase previo al entrenamiento para pacientes de glioma bajo (LGG). A la derecha: coeficiente de Dice por clase post entrenamiento para pacientes de de glioma bajo (LGG)

Fig. 3.5: Coeficiente de Dice pre y post finetuning

Modelo	Dice						HD95					
	Whole		Core		Enh.		Whole		Core		Enh.	
	Mean	Median	Mean	Median	Mean	Median	Mean	Median	Mean	Median	Mean	Median
BL	0.47	0.72	0.55	0.57	0.64	0.80	4.80	4.00	10.62	7.87	2.73	2.23
F	0.60	0.80	0.38	0.15	0.54	0.71	4.94	3	14.45	10.86	7.18	6.08

Tab. 3.1: Tabla comparativa de métricas pre y post entrenamiento de nnU-Net Baseline.

La Figura 3.6 compara la segmentación de ground truth (izquierda), las predicciones iniciales del modelo baseline (centro) y las predicciones del modelo finetuneado (derecha), para un paciente de glioma alto y otro de glioma bajo. El color violeta indica fondo, azul oscuro para edema, amarillo para enhancing tumor y verde para el necrosis y non-enhancing tumor. Observamos en el caso de glioma alto, que el modelo baseline era capaz de identificar correctamente las regiones, pero luego del finetuning fue incapaz de identificar la zona necrótica/no-realzante. Para el caso de glioma bajo, ocurre lo opuesto: el modelo baseline identifica como edema una región que no debe considerarse como tal y luego del finetuning es capaz de identificarlo correctamente.




Fig. 3.6: Las imágenes muestran máscaras de segmentación de un tumor cerebral: Ground truth (izquierda), baseline (centro) y modelo finetuneado (derecha). Cada color representa una región diferente del tumor: violeta indica el fondo, azul oscuro representa el edema, amarillo muestra el tumor realzado y verde denota el núcleo no realzado/necrótico.

Frente a estos resultados, consideramos pertinente consultar a radiólogos expertos en el tema. La segmentación baseline para el glioma de bajo grado indica un sesgo del modelo al identificar incorrectamente regiones de edema en estos casos, aunque la mayoría de los datos de glioma de bajo grado de FLENI no contienen edema. Observamos que en el dataset de BraTS, donde los casos de glioma de bajo y alto grado están mezclados, la mayoría de los ejemplos contienen las tres etiquetas de interés. Tras la consulta, los expertos explicaron que en los casos de glioma de bajo grado es difícil delimitar las diferencias entre las subregiones de edema y tumor no realzante o necrótico. Además, cabe destacar que en los datos de BraTS, la clasificación por grado y las delimitaciones de las subregiones siguen criterios diferentes a los nuestros (FLENI) [42, 1]. Asimismo, los radiólogos expresaron que su interés radica más en delimitar conjuntos de regiones (es decir, identificar correctamente todo el área tumoral completa edema, necrosis/tumor no realzante, tumor

realzante–, el núcleo tumoral –excluyendo edema– y el área que realza) y no tanto en las etiquetas individuales usadas hasta el momento. Por lo tanto, en la siguiente sección 3.3.2 proponemos un nuevo método para segmentar por estas regiones de interés.

Por otra parte, tras una nueva revisión visual de nuestros datos, notamos cuatro ejemplos con datos incompletos: tres de glioma de alto grado y uno de glioma de bajo grado (véase Figura 3.7 para un ejemplo). Aunque existen métodos para imputar datos faltantes o sesgados, decidimos eliminar estos ejemplos para el entrenamiento posterior.




Fig. 3.7: Ejemplo de datos incompletos.

3.3.2. Experimento 2: Entrenamiento por Regiones

Nuestro problema actual pasa de detectar etiquetas individuales a determinar con precisión conjuntos de regiones con etiquetas superpuestas (cf. Figura 3.8):

1. Tumor completo: incluye edema, tumor que no realza y necrosis, y tumor que realza.
2. Núcleo del tumor: comprende tumor que no realza y necrosis, y tumor que realza.
3. Tumor de realce: la parte activa del tumor que aparece de manera prominente en las imágenes con contraste.




Fig. 3.8: Segmentación por regiones. Imágenes de arriba, labels convencionales. Imágenes de abajo, segmentación por regiones usados para entrenar nnU-Net por regiones. Imagen tomada de [43].

El modelo de Isensee et al. (2020) [6] para la competencia de BraTS-2020 aborda eficazmente este problema. Proponen varias modificaciones que permiten que un modelo originalmente diseñado para predecir etiquetas individuales funcione bien en la segmentación de estas regiones críticas. Cabe aclarar que el modelo devuelve como output labels: 1, 2, 3 (edema, necrosis y non-enhancing, enhancing respectivamente) pero al evaluarse por regiones, el rendimiento es superior.

Region Based Training: es un método especializado que mejora el rendimiento de la segmentación al enfocarse en regiones clínicamente relevantes en lugar de etiquetas de clase individuales. En nuestro caso, las etiquetas de entrenamiento suelen ser “edema”, “tumor no realzado y necrosis” y “tumor realzado”. Sin embargo, la evaluación se realiza en tres regiones superpuestas: tumor completo (que comprende las tres clases), núcleo del tumor (incluyendo tumor no realzado, necrosis y tumor realzado), y tumor realzado. Optimizar estas regiones directamente, en lugar de las clases individuales, puede mejorar el rendimiento, particularmente en competencias como BraTS. Para lograr esto, la no linealidad de softmax en la arquitectura de la red se reemplaza con una función sigmoide, y el objetivo de optimización se ajusta para centrarse en las tres subregiones del tumor. Además, la función de pérdida cross-entropy se sustituye por binary cross-entropy, que optimiza independientemente cada región [6].

Mejoras adicionales al modelo nnU-Net incluyen aumentar el tamaño del batch y aplicar técnicas de data augmentation más agresivas. Aumentar el tamaño del batch de 2 a 5 ayuda a reducir el ruido de gradiente y permite que el modelo se ajuste mejor a los datos de entrenamiento. El data augmentation incluye una mayor probabilidad de aplicar rotación y escalado, un rango de escala más amplio, escalado de ejes individuales, deformaciones elásticas, aumentos de brillo. Estos aumentos hacen que el modelo sea más robusto a las variaciones en los datos de entrada, mejorando su rendimiento de segmentación.

Preprocesamiento: Se usó el mismo pipeline de preprocesamiento que en el experimento 1 (3.3.1), descartando los datos incompletos.

Detalles de entrenamiento: El modelo fue finetuneado con 200 epochs, en 2 A100 con aproximadamente 64 núcleos cada uno y tardó menos de dos días.

Evaluación Baseline: Modelo por regiones pre-entrenado evaluado en FLENI

En primer lugar, evaluamos nuestro modelo previo al entrenamiento en los datos de testeo de FLENI. En la Figura 3.8 mostramos estos resultados. Observamos que el modelo baseline tiene un buen desempeño en general. Logra identificar correctamente el área completa del tumor; sin embargo, la clasificación de las subregiones subsiguientes presenta mayores dificultades. Esto se evidencia en la mayor variabilidad observada en los boxplots y en la disminución de las medianas.




Fig. 3.8: Evaluación del modelo baseline en los datos de testeo de FLENI.

Evaluación finetuning

Usamos nuevamente el test de Wilcoxon para comparar entre clases, para Dice y Hausdorff. No se observó diferencias significativa ($\alpha = 0.05$) para whole tumor ($pvalue=0.54$ para Dice y $pvalue=0.42$ para Hausdorff) ni para enhancing tumor ($pvalue=0.43$ para Dice y $pvalue=0.12$ para Hausdorff). Sin embargo se observó una diferencia para tumor core ($pvalue=0.01$ para Dice y $pvalue=0.03$ para Hausdorff). Destacamos que nuestro tamaño de muestra es chica, por lo que el valor de la potencia es baja y limita el análisis que podemos realizar. La Figura 3.9 muestra las métricas de Dice y Hausdorff por clase, notamos que luego de finetunear el modelo, las predicciones de enhancing tumor son menos variadas. Para el gráfico, excluimos por un tema de escala los pacientes 01 y 04. En estos dos casos, el modelo predijo la presencia de tumor realzante (enhancing-tumor) en regiones donde no existía, lo que resultó en una penalización con el valor máximo posible (373.14). Por las razones mencionadas, recomendamos entrenar y evaluar el modelo con mayor cantidad de datos. La Tabla 3.2 muestra las métricas promediadas por clase y entre clase y la Figura 3.10 muestra un ejemplo de segmentación para un caso de glioma alto y bajo.




Fig. 3.9: Rendimiento del modelo finetuneado.

Modelo	Dice Promedio				HD95 Promedio			
	Whole	Core	Enh.	Promedio	Whole	Core	Enh.	Promedio
R-BL	0.87	0.71	0.64	0.74	4.00	6.35	3.71	4.69
R-F	0.89	0.88	0.73	0.83	3.96	3.77	2.03	3.25

Tab. 3.2: Tabla comparativa de métricas pre y post entrenamiento.




Fig. 3.10: Las imágenes muestran segmentaciones de un tumor cerebral: ground truth (izquierda), baseline (centro) y modelo por regiones finetuneado (derecha). Violeta indica el fondo, azul oscuro representa el edema, amarillo muestra el tumor realzado y verde denota necrosis o tumor no realzado. superior: glioma alto, inferior: glioma bajo.

3.4. Clasificación RANO

En esta sección, describimos la metodología empleada para clasificar la respuesta del tumor de glioblastoma utilizando los criterios RANO. Utilizaremos nuestro modelo de segmentación previo, pero ahora con datos de Lumiere. Para este propósito, preprocesamos los datos de la siguiente manera:

El código del pipeline de preprocesamiento realiza las siguientes tareas:

1. Conversión a coordenadas estándar: las imágenes se convierten a coordenadas estándar utilizando `fslreorient2std` de FSL [30].
2. Las imágenes T1 ce se resamplean a un volumen constante de $240 \times 240 \times 155$ voxels con tamaño isotrópico de $1mm^3$.
3. Las secuencias T1, T2 y FLAIR se coregistran a la imagen T1 ce resampleadas utilizando el algoritmo `fslirt` de FSL [30].
4. Las segmentaciones dadas por DeepBraTumIA se resamplean a un volumen constante para asegurar consistencia.

Una vez preprocesados los datos, usamos el modelo entrenado en la etapa anterior para segmentar y guardamos las segmentaciones para realizar la clasificación RANO. El paso inicial consiste en generar un archivo JSON que capture los volúmenes por etiqueta para cada paciente en cada punto temporal y cada método: DeepBraTumIA y nnUNet. A partir de esto, para cada paciente, se crea un informe detallado que abarca varios aspectos críticos,

siguiendo la figura del paper [3]. Este informe incluye una secuencia de imágenes (MRI) a lo largo de diferentes puntos temporales, proporcionando una línea temporal visual de la progresión del tumor. Además, se incluyen las segmentaciones correspondientes para cada algoritmo (DeepBraTumIA, nnUNet), permitiendo un análisis comparativo de su rendimiento. Las etiquetas de referencia derivadas de anotaciones de expertos utilizando los criterios RANO y un gráfico de la progresión del volumen del label enhancing tumor. En la Figura 3.11 se muestra un ejemplo del reporte.

Para realizar la clasificación automatizada de RANO (AI RANO), utilizaremos únicamente las segmentaciones, es decir, los datos volumétricos. El proceso implica comparar el volumen del tumor realzante en diferentes instantes temporales. Específicamente, compararemos el volumen del tumor realzante en cada instante t con el volumen en el instante anterior $t - 1$.

Seguiremos los lineamientos de Wen et al. (2023) [4], que proporcionan una metodología para la clasificación basada en datos volumétricos. A continuación, describimos el Algoritmo 1, que establece los pasos detallados para la clasificación según los criterios RANO. La Figura 3.12 muestra una comparación de la clasificación por expertos y por nuestro método.

Algorithm 1 Clasificación RANO basado en diferencia volumétrica

Require: Diccionario del paciente donde para cada semana, se tiene el volumen de enhancing tumor.

```

1:  $V_0 \leftarrow$  volumen pre-operativo (Semana 0)
2:  $V_1 \leftarrow$  volumen post-operativo (Semana 1)
3: if solo se tienen datos post-operativos then
4:    $V_0 \leftarrow V_1$ 
5: end if
6: for cada semana  $t$  desde la Semana 2 hasta la última semana de datos do
7:    $\Delta_{t,t-1} \leftarrow V_t - V_{t-1}$  ▷ Calcular la diferencia de volumen
8:    $\Delta_{t,t-1} \leftarrow \left( \frac{\Delta_{t,t-1}}{V_{t-1}} \right) \times 100$  ▷ Convertir a porcentaje
9:   if  $\Delta_{t,t-1} = -100$  then
10:    Clasificación en la semana  $t \leftarrow$  CR (Respuesta Completa)
11:   else if  $-100 < \Delta_{t,t-1} \leq -65$  then
12:    Clasificación en la semana  $t \leftarrow$  PR (Respuesta Parcial)
13:   else if  $\Delta_{t,t-1} > 40$  then
14:    Clasificación en la semana  $t \leftarrow$  PD (Enfermedad Progresiva)
15:   else
16:    Clasificación en la semana  $t \leftarrow$  SD (Enfermedad Estable)
17:   end if
18: end for
```




Fig. 3.11: Ejemplo del reporte creado




Fig. 3.12: Comparación de clasificación RANO usando nuestro método (nnU-Net) y etiquetas verdaderas..

Evaluación

Cabe destacar que debido a la falta de segmentaciones verdaderas, es difícil comparar los resultados automatizados. La evaluación de nuestro método será meramente cualitativa. En primer lugar, las curvas de progresión de volumen realizada por nuestro modelo (nnU-Net) se asemejan a las curvas de DeepBraTumIA (cf. Figura 3.12). Hay casos particulares en donde hay discrepancia en las curvas (cf. Figura 3.13) pero siguen tendencias similares. Asimismo, notamos que la clasificación RANO, a diferencia de la segmentación, sí es validada por expertos.




Fig. 3.13: Comparación de clasificación RANO usando nuestro método y etiquetas verdaderas.

En la Figura 3.14 observamos la matriz de confusión de las predicciones usando nnU-Net y DeepBraTumIA. El modelo nnU-Net (Figura 3.14a) tiene dificultades para predecir con precisión la Respuesta Completa (CR) y la Respuesta Parcial (PR), sin predicciones correctas para CR y solo una para PR. Muchas instancias de CR se clasifican erróneamente como Enfermedad Estable (SD), y las instancias de PR a menudo se confunden con CR o SD. Si bien muestra un mejor desempeño con SD, prediciendo correctamente 78 instancias, aún tiene clasificaciones incorrectas. Un problema importante es la alta tasa de clasificación errónea de la Enfermedad Progresiva (PD), con muchos casos de PD etiquetados incorrectamente como SD. El modelo DeepBraTumIA (Figura 3.14b) clasifica correctamente solo 4 instancias de CR y 11 de PR. Tiene peor desempeño que nnU-Net en SD, clasificando solamente correctamente 44 instancias como tales. Pero presenta una mejor clasificación en PD, al identificar correctamente 113 instancias. Resumimos los valores

en la Tabla 3.3, notamos que ninguno de los modelos presenta buen desempeño.

A partir de estos resultados obtenidos, consideramos que los métodos de segmentación son insuficientes para proveer una clasificación RANO a nivel clínico. No obstante, los gráficos de progresión volumétrica sí pueden ayudar al médico en las instancias de seguimiento. En [7], se demuestra que al incluir gráficos de progresión de técnicas automáticas mejora la consistencia de la evaluación entre radiólogo, en comparación con las evaluaciones bidimensionales usando solamente los criterios RANO.




Fig. 3.14: Matrices de confusión para clasificación RANO usando nnU-Net (a) y DeepBraTumIA (b).

Categoría	DeepBraTumIA F1	nnU-Net F1
CR	0.154	0.000
PR	0.344	0.074
SD	0.342	0.402
PD	0.590	0.258

Tab. 3.3: Comparación de F1 por categoría usando DeepBraTumIA y nnU-Net.

3.5. Resumen

En resumen, nuestra metodología para segmentar tumores implicó aprovechar el modelo nnU-Net preentrenado en BraTS 2020 y usar region-based training. Utilizamos el conjunto de datos de FLENI para finetunear el modelo y obtuvimos rendimiento deseables. Luego, evaluamos en los datos longitudinales de LUMIERE para realizar la tarea de clasificación RANO, donde se requiere de un mejor modelo para establecer la clasificación según RANO.

4. CONCLUSIONES

Los objetivos principales de esta tesis se centran en la segmentación de tumores cerebrales y en proporcionar una evaluación RANO basada en la segmentación obtenida.

Las metodologías empleadas en este estudio incluyen el uso del modelo nnU-Net, con region-based training, el cual fue preentrenado inicialmente en el dataset BraTS 2020 y posteriormente fine-tuneado utilizando el dataset FLENI para mejorar la segmentación de tumores en este último dataset.

El marco de evaluación para la segmentación se basa en Dice score y la distancia de Hausdorff de percentil 95, y se evalúan utilizando regiones superpuestas: tumor completo, núcleo del tumor y tumor que realza. La comparación entre el modelo baseline y el finetuneado reveló mejoras de la segmentación gracias al fine-tuning. El score de Dice promediado en todas las etiquetas aumentó de 0.74 a 0.83. Y la distancia de Hausdorff de percentil 95 disminuyó de 4.69 a 3.25 (mm).

Además, se evaluó el rendimiento del modelo utilizando el dataset longitudinal LUMIERE para llevar a cabo la clasificación según RANO. Los criterios RANO se implementaron siguiendo un algoritmo basado únicamente en las diferencias volumétricas del tumor que realza entre el momento actual y el anterior. Sin embargo, existen dificultades, particularmente en la clasificación RANO, donde el análisis volumétrico resultó insuficiente y mostró problemas de clasificación errónea. Estos hallazgos subrayan las complejidades de clasificar con precisión las respuestas tumorales y destacan la necesidad de una mejores modelos de segmentación o la inclusión de datos más diversos para una clasificación RANO correcta.

A pesar de estos desafíos, los gráficos de progresión volumétrica desarrollados en este estudio tienen un potencial significativo para ayudar a los médicos a monitorear la progresión del tumor y la respuesta al tratamiento. Estos gráficos ofrecen algunas ideas sobre los cambios temporales en el volumen del tumor, ayudando así en la evaluación de la eficacia terapéutica y apoyando los procesos de toma de decisiones clínicas.

4.1. Limitaciones y trabajos futuros

Reconocemos varias limitaciones relacionadas con el tamaño y la diversidad de los datasets utilizados. Un problema significativo es el domain-shift, observado cuando el modelo entrenado en BraTS se evaluó en FLENI con las etiquetas de subregiones del tumor: edema, necrosis/tumor no realzante y tumor realzante; esto indica la dificultad del modelo para generalizar.

Si bien nuestros datasets poseen proporciones balanceadas de varones y mujeres, no realizamos un análisis segregado por sexo. Este análisis sería interesante de llevar a cabo, ya que los modelos pueden presentar sesgos que afecten su rendimiento dependiendo del género de los pacientes. Investigar estas posibles disparidades permitiría identificar y mitigar sesgos, mejorando la equidad y la eficacia clínica de los modelos de segmentación y clasificación.

Los métodos de segmentación actuales tienen limitaciones para proporcionar clasificaciones RANO clínicamente útiles, como lo evidencian las altas tasas de clasificación erróneas para las categorías de Respuesta Completa (CR), Respuesta Parcial (PR) y Enfermedad Progresiva (PD). Esto destaca la importancia del desarrollo de técnicas de seg-

mentación para garantizar evaluaciones de respuesta tumoral más fiables a lo largo del tiempo. Para mejorar la clasificación RANO, la investigación futura debería integrar modelos de segmentación avanzados con flujos de trabajo clínicos para mejorar la utilidad práctica. Esto implica desarrollar algoritmos para mediciones precisas del volumen tumoral y garantizar un rendimiento consistente en variados entornos.

En primer lugar, es crucial un mejor workflow en el trabajo de segmentación, considerando las limitaciones del modelo utilizado en esta tesis, que tiene soporte limitado y una base de código complicada. Nuevos frameworks como MONAI [44] y nnU-Net v2 simplifican el esfuerzo de programación, ofreciendo herramientas intuitivas y fáciles de usar que mejoran la reproducibilidad e integración clínica.

En segundo lugar, la exploración de arquitecturas y técnicas avanzadas de deep learning sigue siendo crucial para mejorar la capacidad de generalización. Sin embargo, como se demuestra en [45], una nueva arquitectura no significa un mejor rendimiento; es más vital asegurar que estas innovaciones se validen rigurosamente para evaluar verdaderamente su eficacia. Por ejemplo, el dataset BraTS tiene baja varianza sistemática, lo que lo hace menos fiable para evaluar avances metodológicos generales.

Por último, como se demuestra en [46], se podrían explorar la viabilidad y los beneficios del aprendizaje en conjunto a partir de diversas bases de datos de MRI. Al entrenar modelos en datasets con varias enfermedades cerebrales y modalidades de imagen, estos modelos pueden desempeñarse bien en diferentes condiciones clínicas.

BIBLIOGRAFÍA

- [1] Spyridon Bakas et al. *Identifying the Best Machine Learning Algorithms for Brain Tumor Segmentation, Progression Assessment, and Overall Survival Prediction in the BRATS Challenge*. 2019. arXiv: [1811.02629 \[cs.CV\]](#).
- [2] Zhihua Liu, Lei Tong, Zheheng Jiang, Long Chen, Feixiang Zhou, Qianni Zhang, Xiangrong Zhang, Yaochu Jin y Huiyu Zhou. *Deep Learning Based Brain Tumor Segmentation: A Survey*. 2021. arXiv: [2007.09479 \[eess.IV\]](#).
- [3] Yannick Suter, Urspeter Knecht, Waldo Valenzuela, Michelle Notter, Ekkehard Heuer, Philippe Schuch, Roland Wiest y Mauricio Reyes. «The LUMIERE dataset: Longitudinal Glioblastoma MRI with expert RANO evaluation». en: *En: Sci. Data* 9.1 (dic. de 2022), pág. 768.
- [4] Patrick Y. Wen et al. «RANO 2.0: Update to the Response Assessment in Neuro-Oncology Criteria for High- and Low-Grade Gliomas in Adults». En: *Journal of Clinical Oncology* 41.33 (nov. de 2023), págs. 5187-5199. ISSN: 1527-7755. DOI: [10.1200/jco.23.01059](#). URL: <http://dx.doi.org/10.1200/JCO.23.01059>.
- [5] Fabian Isensee, Paul F. Jaeger, Simon A. A. Kohl, Jens Petersen y Klaus H. Maier-Hein. «nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation». En: *Nature Methods* 18.2 (feb. de 2021), págs. 203-211. ISSN: 1548-7105. DOI: [10.1038/s41592-020-01008-z](#). URL: <https://doi.org/10.1038/s41592-020-01008-z>.
- [6] Fabian Isensee, Paul F. Jaeger, Peter M. Full, Philipp Vollmuth y Klaus H. Maier-Hein. *nnU-Net for Brain Tumor Segmentation*. 2020. arXiv: [2011.00848 \[eess.IV\]](#).
- [7] Philipp Vollmuth et al. «Artificial intelligence (AI)-based decision support improves reproducibility of tumor response assessment in neuro-oncology: An international multi-reader study». En: *Neuro-Oncology* 25.3 (ago. de 2022), págs. 533-543. ISSN: 1523-5866. DOI: [10.1093/neuonc/noac189](#). URL: <http://dx.doi.org/10.1093/neuonc/noac189>.
- [8] Infobae. *Tumores cerebrales: síntomas, diagnóstico y tratamiento de una enfermedad que afecta a unas 300 mil personas al año*. 2022. URL: <https://www.infobae.com/salud/ciencia/2022/06/08/tumores-cerebrales-sintomas-diagnostico-y-tratamiento-de-una-enfermedad-que-afecta-a-unas-300-mil-personas-al-ano/> (visitado 01-06-2024).
- [9] WHO Classification of Tumours Editorial Board. *Central Nervous System Tumours*. 5.^a ed. Vol. 6. World Health Organization, 2021. ISBN: 978-92-832-4508-7.
- [10] Irena Ilic y Milena Ilic. «International patterns and trends in the brain cancer incidence and mortality: An observational study based on the global burden of disease». En: *Heliyon* 9.7 (jul. de 2023), e18222. ISSN: 2405-8440. DOI: [10.1016/j.heliyon.2023.e18222](#). URL: <http://dx.doi.org/10.1016/j.heliyon.2023.e18222>.
- [11] Instituto Nacional del Cáncer. *Estadísticas - Incidencia*. 2021. URL: <https://www.argentina.gob.ar/salud/instituto-nacional-del-cancer/estadisticas/incidencia> (visitado 01-06-2024).

-
- [12] Hospital Italiano de Buenos Aires. *Tumores Cerebrales*. 2021. URL: <https://www1.hospitalitaliano.org.ar/#!/home/neurocirugia/seccion/1264> (visitado 01-06-2024).
- [13] Mckinsey L Goodenberger y Robert B Jenkins. «Genetics of adult glioma». en. En: *Cancer Genet* 205.12 (dic. de 2012), págs. 613-621.
- [14] World Health Organization. *International classification of diseases for oncology (ICD-O)*. 3rd ed., 1st revision. World Health Organization, 2013, viii, 242 p.
- [15] Felix Lugauer y Jens Wetzl. «Magnetic Resonance Imaging». En: *Medical Imaging Systems: An Introductory Guide*. Ed. por Andreas Maier, Stefan Steidl, Vincent Christlein y Joachim Hornegger. Cham: Springer International Publishing, 2018, págs. 91-118. ISBN: 978-3-319-96520-8. DOI: [10.1007/978-3-319-96520-8_6](https://doi.org/10.1007/978-3-319-96520-8_6). URL: https://doi.org/10.1007/978-3-319-96520-8_6.
- [16] Bjoern H Menze et al. «The Multimodal Brain Tumor Image Segmentation Benchmark (BRATS)». en. En: *IEEE Trans. Med. Imaging* 34.10 (oct. de 2015), págs. 1993-2024.
- [17] Dmitry Yarotsky. «Error bounds for approximations with deep ReLU networks». En: *CoRR* abs/1610.01145 (2016). arXiv: [1610.01145](https://arxiv.org/abs/1610.01145). URL: <http://arxiv.org/abs/1610.01145>.
- [18] Hongzhou Lin y Stefanie Jegelka. «ResNet with one-neuron hidden layers is a Universal Approximator». En: *CoRR* abs/1806.10909 (2018). arXiv: [1806.10909](https://arxiv.org/abs/1806.10909). URL: <http://arxiv.org/abs/1806.10909>.
- [19] Wikimedia Commons. *File:Example of a deep neural network.png — Wikimedia Commons, the free media repository*. [Online; accessed 11-June-2024]. 2024. URL: https://commons.wikimedia.org/w/index.php?title=File:Example_of_a_deep_neural_network.png&oldid=880569436.
- [20] Jonathan Long, Evan Shelhamer y Trevor Darrell. *Fully Convolutional Networks for Semantic Segmentation*. 2015. arXiv: [1411.4038](https://arxiv.org/abs/1411.4038) [cs.CV].
- [21] Wikimedia Commons. *File:Typical cnn.png — Wikimedia Commons, the free media repository*. [Online; accessed 11-June-2024]. 2022. URL: https://commons.wikimedia.org/w/index.php?title=File:Typical_cnn.png&oldid=671717156.
- [22] Olaf Ronneberger, Philipp Fischer y Thomas Brox. *U-Net: Convolutional Networks for Biomedical Image Segmentation*. 2015. arXiv: [1505.04597](https://arxiv.org/abs/1505.04597) [cs.CV].
- [23] Fabian Isensee, Constantin Ulrich, Tassilo Wald y Klaus H. Maier-Hein. *Extending nnU-Net is all you need*. 2022. arXiv: [2208.10791](https://arxiv.org/abs/2208.10791) [eess.IV].
- [24] E. Alberts, B. Menze y C. Zimmer. *Multi-modal Multi-temporal Brain Tumor Segmentation, Growth Analysis and Texture-based Classification*. Universitätsbibliothek der TU München, 2019. URL: <https://mediatum.ub.tum.de/doc/1453649/137528.pdf>.
- [25] Sarah Parisot. «Understanding, Modeling and Detecting Brain Tumors : Graphical Models and Concurrent Segmentation/Registration methods». Theses. Ecole Centrale Paris, nov. de 2013. URL: <https://theses.hal.science/tel-00978520>.

-
- [26] Tongxue Zhou, Su Ruan, Yu Guo y Stephane Canu. «A Multi-Modality Fusion Network Based on Attention Mechanism for Brain Tumor Segmentation». En: *2020 IEEE 17th International Symposium on Biomedical Imaging (ISBI)*. IEEE, abr. de 2020. DOI: [10.1109/isbi45749.2020.9098392](https://doi.org/10.1109/isbi45749.2020.9098392). URL: <http://dx.doi.org/10.1109/ISBI45749.2020.9098392>.
- [27] Ramin Ranjbarzadeh, Abbas Bagherian Kasgari, Saeid Jafarzadeh Ghouschi, Shokofeh Anari, Maryam Naseri y Malika Bendeche. «Brain tumor segmentation based on deep learning and an attention mechanism using MRI multi-modalities brain images». en. En: *Sci. Rep.* 11.1 (mayo de 2021), pág. 10930.
- [28] Paul A. Yushkevich, Joseph Piven, Heather Cody Hazlett, Rachel Gimpel Smith, Sean Ho, James C. Gee y Guido Gerig. «User-Guided 3D Active Contour Segmentation of Anatomical Structures: Significantly Improved Efficiency and Reliability». En: *Neuroimage* 31.3 (2006), págs. 1116-1128.
- [29] Matthew Brett et al. *nipy/nibabel: 5.2.1*. Ver. 5.2.1. Feb. de 2024. DOI: [10.5281/zenodo.10714563](https://doi.org/10.5281/zenodo.10714563). URL: <https://doi.org/10.5281/zenodo.10714563>.
- [30] M. Jenkinson, Christian Beckmann, T.E.J. Behrens, Mark W. Woolrich y S.M. Smith. «FSL». English. En: *NeuroImage* 62.2 (2012), págs. 782-790. ISSN: 1053-8119. DOI: [10.1016/j.neuroimage.2011.09.015](https://doi.org/10.1016/j.neuroimage.2011.09.015).
- [31] Juan Eugenio Iglesias, Cheng-Yi Liu, Paul M. Thompson y Zhuowen Tu. «Robust Brain Extraction Across Datasets and Comparison With Publicly Available Methods». En: *IEEE Transactions on Medical Imaging* 30.9 (2011), págs. 1617-1634. DOI: [10.1109/TMI.2011.2138152](https://doi.org/10.1109/TMI.2011.2138152).
- [32] Abdel Aziz Taha y Allan Hanbury. «Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool». En: *BMC Medical Imaging* 15.1 (ago. de 2015). ISSN: 1471-2342. DOI: [10.1186/s12880-015-0068-x](https://doi.org/10.1186/s12880-015-0068-x). URL: <http://dx.doi.org/10.1186/s12880-015-0068-x>.
- [33] Dominik Müller, Iñaki Soto-Rey y Frank Kramer. *Towards a Guideline for Evaluation Metrics in Medical Image Segmentation*. 2022. arXiv: [2202.05273](https://arxiv.org/abs/2202.05273) [eess.IV].
- [34] Doruk Oner, Mateusz Kozinski, Lenoardo Citraro y Pascal Fua. «Adjusting the Ground Truth Annotations for Connectivity-Based Learning to Delineate». En: *IEEE Transactions on Medical Imaging* 41.12 (dic. de 2022), págs. 3675-3685. ISSN: 1558-254X. DOI: [10.1109/tmi.2022.3193072](https://doi.org/10.1109/tmi.2022.3193072). URL: <http://dx.doi.org/10.1109/TMI.2022.3193072>.
- [35] Nicolás Gaggion, Rodrigo Echeveste, Lucas Mansilla, Diego H. Milone y Enzo Ferrante. *Unsupervised bias discovery in medical image segmentation*. 2023. arXiv: [2309.00451](https://arxiv.org/abs/2309.00451) [cs.CV].
- [36] Spyridon Bakas, Hamed Akbari, Aristeidis Sotiras, Michel Bilello, Martin Rozycki, Justin S Kirby, John B Freymann, Keyvan Farahani y Christos Davatzikos. «Advancing The Cancer Genome Atlas glioma MRI collections with expert segmentation labels and radiomic features». en. En: *Sci. Data* 4.1 (sep. de 2017), pág. 170117.
- [37] Spyridon Bakas, Hamed Akbari, Aristeidis Sotiras, Michel Bilello, Martin Rozycki, Justin Kirby, John Freymann, Keyvan Farahani y Christos Davatzikos. «Segmentation labels and radiomic features for the pre-operative scans of the TCGA-LGG collection». En: *The Cancer Imaging Archive* (2017).

-
- [38] Spyridon Bakas, Hamed Akbari, Aristeidis Sotiras, Michel Bilello, Martin Rozycki, Justin Kirby, John Freymann, Keyvan Farahani y Christos Davatzikos. *Segmentation labels and radiomic features for the pre-operative scans of the TCGA-GBM collection. The Cancer Imaging Archive*. 2017.
- [39] Ujjwal Baid et al. *The RSNA-ASNR-MICCAI BraTS 2021 Benchmark on Brain Tumor Segmentation and Radiogenomic Classification*. 2021. arXiv: [2107.02314 \[cs.CV\]](#).
- [40] Philipp Kickingeder et al. «Automated quantitative tumour response assessment of MRI in neuro-oncology with artificial neural networks: a multicentre, retrospective study». En: *The Lancet Oncology* 20.5 (mayo de 2019), págs. 728-740. ISSN: 1470-2045. DOI: [10.1016/s1470-2045\(19\)30098-1](#). URL: [http://dx.doi.org/10.1016/S1470-2045\(19\)30098-1](http://dx.doi.org/10.1016/S1470-2045(19)30098-1).
- [41] Fabian Isensee et al. «Automated brain extraction of multisequence MRI using artificial neural networks». En: *Human Brain Mapping* 40.17 (ago. de 2019), págs. 4952-4964. ISSN: 1097-0193. DOI: [10.1002/hbm.24750](#). URL: <http://dx.doi.org/10.1002/hbm.24750>.
- [42] P. Dequidt, P. Bourdon, B. Tremblais, C. Guillevin, B. Gianelli, C. Boutet, J.-P. Cottier, J.-N. Vallée, C. Fernandez-Maloigne y R. Guillevin. «Exploring Radiologic Criteria for Glioma Grade Classification on the BraTS Dataset». En: *IRBM* 42.6 (dic. de 2021), págs. 407-414. ISSN: 1959-0318. DOI: [10.1016/j.irbm.2021.04.003](#). URL: <http://dx.doi.org/10.1016/j.irbm.2021.04.003>.
- [43] Fabian Isensee et al. *Region Based Training*. GitHub. Accessed: 2024-06-12. 2024. URL: https://github.com/MIC-DKFZ/nnUNet/blob/master/documentation/region_based_training.md.
- [44] M. Jorge Cardoso et al. *MONAI: An open-source framework for deep learning in healthcare*. 2022. arXiv: [2211.02701 \[cs.LG\]](#).
- [45] Fabian Isensee, Tassilo Wald, Constantin Ulrich, Michael Baumgartner, Saikat Roy, Klaus Maier-Hein y Paul F. Jaeger. *nnU-Net Revisited: A Call for Rigorous Validation in 3D Medical Image Segmentation*. 2024. arXiv: [2404.09556 \[cs.CV\]](#).
- [46] Wentian Xu et al. *Feasibility and benefits of joint learning from MRI databases with different brain diseases and modalities for segmentation*. 2024. arXiv: [2405.18511 \[cs.CV\]](#).