




Fig. 2.7: Overview de segmentación de tumores cerebrales

Notemos que en la práctica, las imágenes son discretizadas. Consideramos que esta cuantización se obtiene a partir de un muestreo de la distribución original, por lo que un vóxel ($\in \mathbb{R}^3$) o un píxel ($\in \mathbb{R}^2$) es solamente una muestra de la imagen.

Definición 2.3.1 (Segmentación de tumores cerebrales). Dado una imagen perteneciente a un dataset $\mathcal{I} \in \mathcal{D}$ con cuatro modalidades, el problema de segmentación tumoral busca delimitar las distintas regiones tumorales en el cerebro. Esto es, clasificar cada vóxel o píxel del input en las regiones tumorales definidas (e.g: fondo, edema, necrosis, tumor realzante).

$$\hat{\mathcal{I}}_{\text{seg}} = f_{\theta}(\mathcal{I}), \quad (2.1)$$

donde $f_{\theta} : \mathcal{V} \rightarrow \mathcal{L}$ es una función de parámetros θ que clasifica cada voxel $\mathcal{I}^{(i)}$ de la imagen en la región correspondiente: $\hat{\mathcal{I}}^{(i)} \in \mathcal{L} = \cup_{k=0}^K \ell_k$, con ℓ_k un label particular. E.g. f_{θ} es una red neuronal cuyos pesos entrenables son θ . La Figura 2.7 muestra un diagrama esquemático para una tarea de una segmentación.

Adicionalmente, para cada paciente podemos considerar distintas secuencias de imágenes tomadas en diferentes momentos: $\{\mathcal{I}_t\}_{t=0}^T$. Estas secuencias son referidas como dataset longitudinal. En la Figura 2.8 mostramos un ejemplo de un dataset longitudinal para un paciente dado. Formalizamos entonces el problema de clasificación según criterio RANO de la siguiente manera:

Definición 2.3.2 (Clasificación RANO). Dado un paciente $i \in [1, \dots, N]$, con distintas imágenes MRI tomadas a distinto tiempo t (medidas en días o semanas): $\mathcal{I}_0, \dots, \mathcal{I}_T$, con sus respectivas segmentaciones dadas por una función $f : \mathcal{V} \rightarrow \mathcal{L}$, que devuelva la imagen segmentada con los regiones de interés (e.g.: enhancing tumor, necrosis, etc.). Consideramos $\mathcal{I}_0$ el estado del paciente previo a la resección e $\mathcal{I}_1$ el estado luego de la resección. Podemos clasificar cada imagen según el criterio RANO:

$$\mathcal{R} = \{\text{Stable disease, Partial response, Complete Response, Progressive disease}\}$$




Fig. 2.8: Longitudinal imaging of a brain tumor over a span of 49 weeks. The images show four different imaging modalities: CT1, T1, T2, and FLAIR, taken at various time points (0 days, 3 days, 13 weeks, 23 weeks, 45 weeks, and 49 weeks). Each row represents a different modality, and each column represents a different time point, illustrating the progression and changes in the tumor over time. Image taken from [3].

Esto es, existe una función $g : \mathcal{L} \rightarrow \mathcal{R}$ tal que:

$$g(f(\mathcal{I}_0)) = \text{Pre-operative} \quad (2.2)$$

$$g(f(\mathcal{I}_1)) = \text{Complete Resection} \quad (2.3)$$

$$g(f(\mathcal{I}_t)) = r \in \mathcal{R} \quad \forall t > 1 \quad (2.4)$$

En teoría, la función g es una función basada en reglas y determinada según criterios clínicos y tomando en cuenta las imágenes segmentadas de tiempos anteriores. Existen diversas formas de clasificar según RANO, según la versión del criterio, la decisión del neuroradiólogo y las condiciones clínicas del paciente.

Para simplificar este proceso, nuestro criterio RANO estará basada en clasificar la diferencia volumétrica para cada par de tiempo. Para ello, nos bastará tomar la imagen segmentada $\mathcal{I}_{t,\text{seg}}$ y calcular el volumen de la región de interés ℓ_k para el tiempo t :

$$\text{Vol}_k(\mathcal{I}_{\text{seg}}) = \sum_{x \in \Omega} \mathbb{1}_{\{\mathcal{I}_{\text{seg}} = \ell_k\}}(x) \quad (2.5)$$

Esto es, para cada región de interés calcular el volumen (o su proporción) contando la cantidades de voxels de esa determinada región. Referimos al lector a la sección 3.4 para más detalles sobre la implementación.




Fig. 3.10: Las imágenes muestran segmentaciones de un tumor cerebral: ground truth (izquierda), baseline (centro) y modelo por regiones finetuneado (derecha). Violeta indica el fondo, azul oscuro representa el edema, amarillo muestra el tumor realzado y verde denota necrosis o tumor no realzado. superior: glioma alto, inferior: glioma bajo.

3.4. Clasificación RANO

En esta sección, describimos la metodología empleada para clasificar la respuesta del tumor de glioblastoma utilizando los criterios RANO. Utilizaremos nuestro modelo de segmentación previo, pero ahora con datos de Lumiere. Para este propósito, preprocesamos los datos de la siguiente manera:

El código del pipeline de preprocesamiento realiza las siguientes tareas:

1. Conversión a coordenadas estándar: las imágenes se convierten a coordenadas estándar utilizando `fslreorient2std` de FSL [30].
2. Las imágenes T1 ce se resamplean a un volumen constante de $240 \times 240 \times 155$ voxeles con tamaño isotrópico de $1mm^3$.
3. Las secuencias T1, T2 y FLAIR se coregistran a la imagen T1 ce resampleadas utilizando el algoritmo `fslirt` de FSL [30].
4. Las segmentaciones dadas por DeepBraTumIA se resamplean a un volumen constante para asegurar consistencia.

Una vez preprocesados los datos, usamos el modelo entrenado en la etapa anterior para segmentar y guardamos las segmentaciones para realizar la clasificación RANO. El paso inicial consiste en generar un archivo JSON que capture los volúmenes por etiqueta para cada paciente en cada punto temporal y cada método: DeepBraTumIA y nnUNet. A partir de esto, para cada paciente, se crea un informe detallado que abarca varios aspectos críticos,

siguiendo la figura del paper [3]. Este informe incluye una secuencia de imágenes (MRI) a lo largo de diferentes puntos temporales, proporcionando una línea temporal visual de la progresión del tumor. Además, se incluyen las segmentaciones correspondientes para cada algoritmo (DeepBraTumIA, nnUNet), permitiendo un análisis comparativo de su rendimiento. Las etiquetas de referencia derivadas de anotaciones de expertos utilizando los criterios RANO y un gráfico de la progresión del volumen del label enhancing tumor. En la Figura 3.11 se muestra un ejemplo del reporte.

Para realizar la clasificación automatizada de RANO (AI RANO), utilizaremos únicamente las segmentaciones, es decir, los datos volumétricos. El proceso implica comparar el volumen del tumor realzante en diferentes instantes temporales. Específicamente, compararemos el volumen del tumor realzante en cada instante t con el volumen en el instante anterior $t - 1$.

Seguiremos los lineamientos de Wen et al. (2023) [4], que proporcionan una metodología para la clasificación basada en datos volumétricos. A continuación, describimos el Algoritmo 1, que establece los pasos detallados para la clasificación según los criterios RANO. La Figura 3.12 muestra una comparación de la clasificación por expertos y por nuestro método.

Algorithm 1 Clasificación RANO basado en diferencia volumétrica

Require: Diccionario del paciente donde para cada semana, se tiene el volumen de enhancing tumor.

```

1:  $V_0 \leftarrow$  volumen pre-operativo (Semana 0)
2:  $V_1 \leftarrow$  volumen post-operativo (Semana 1)
3: if solo se tienen datos post-operativos then
4:    $V_0 \leftarrow V_1$ 
5: end if
6: for cada semana  $t$  desde la Semana 2 hasta la última semana de datos do
7:    $\Delta_{t,t-1} \leftarrow V_t - V_{t-1}$  ▷ Calcular la diferencia de volumen
8:    $\Delta_{t,t-1} \leftarrow \left( \frac{\Delta_{t,t-1}}{V_{t-1}} \right) \times 100$  ▷ Convertir a porcentaje
9:   if  $\Delta_{t,t-1} = -100$  then
10:    Clasificación en la semana  $t \leftarrow$  CR (Respuesta Completa)
11:   else if  $-100 < \Delta_{t,t-1} \leq -65$  then
12:    Clasificación en la semana  $t \leftarrow$  PR (Respuesta Parcial)
13:   else if  $\Delta_{t,t-1} > 40$  then
14:    Clasificación en la semana  $t \leftarrow$  PD (Enfermedad Progresiva)
15:   else
16:    Clasificación en la semana  $t \leftarrow$  SD (Enfermedad Estable)
17:   end if
18: end for
```
